

Laporan Project
Mata Kuliah Metode Peramalan



disusun oleh :

Riandika Rafael Jaya Pangaribuan (2306242874)

Darryl Jetro Hezekia Sinaga (2306249722)

Aulia Rahma Kusuma (2306209302)

Muhammad HaekkalRamadhan (2306249760)

DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS INDONESIA

2025

TABEL KONTRIBUSI

Nama	NPM	Kontribusi	Tingkat Kontribusi
Riandika Rafael Jaya Pangaribuan	2306242874	Spesifikasi Model dan Estimasi Parameter	100%
Darryl Jetro Hezekia Sinaga	2306249722	EDA dan Uji Stasioner	100%
Aulia Rahma Kusuma	2306209302	Model Diagnosis dan Forecasting	100%
Muhammad HaekkalRamadhan	2306249760	Pendahuluan, Metode Analisis, dan Penutup	100%

DAFTAR PUSTAKA

TABEL KONTRIBUSI.....	2
DAFTAR PUSTAKA.....	3
BAB I PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah.....	4
1.3 Tujuan Penelitian.....	4
BAB II METODE PENELITIAN.....	5
2.1 Variabel Penelitian.....	5
2.2 Pre-Processing.....	6
2.2.1 Load Data.....	6
2.2.2 Informasi Data.....	6
2.2.3 Memeriksa Missing Value.....	7
2.3 Metode Analisis.....	7
2.3.1 ARIMA.....	7
2.3.2 SARIMA.....	7
2.3.3 GARCH.....	8
BAB III HASIL DAN PEMBAHASAN.....	9
3.1 Exploratory Data Analysis (EDA).....	9
3.1.1 Mengambil Kolom “Date” dan “Adj.Close” serta Persiapan Data.....	9
3.1.2 Statistik Deskriptif.....	9
3.1.4 Visualisasi Distribusi Harga Adjusted Close.....	11
3.1.5 Visualisasi Volatilitas Data.....	12
3.2.3 Plot ACF.....	15
3.3 Spesifikasi Model.....	17
3.3.1 Model ARIMA.....	17
3.3.2 Model SARIMA.....	20
3.3.3 Model GARCH.....	21
3.4 Estimasi Parameter.....	22
3.5 Model Diagnostik.....	25
3.5.1 analisis residual (white noise).....	25
3.5.2 Overfitting.....	27
3.5.3 Forecasting.....	29
BAB IV PENUTUP.....	31
4.1 Kesimpulan.....	31
4.2 Saran.....	31
LAMPIRAN.....	32

BAB I PENDAHULUAN

1.1 Latar Belakang

Pasar saham merupakan indikator penting bagi kondisi ekonomi suatu negara maupun perusahaan secara individual. Pergerakan harga saham mencerminkan ekspektasi investor terhadap kinerja masa depan perusahaan, kondisi makroekonomi, serta dinamika pasar global. Oleh karena itu, kemampuan untuk melakukan peramalan terhadap harga saham menjadi krusial, baik bagi investor, analis keuangan, maupun perusahaan itu sendiri.

IBM (International Business Machines Corporation) merupakan salah satu perusahaan teknologi terbesar dan tertua di dunia, dengan sahamnya tercatat di pasar saham Amerika Serikat. Dengan perkembangan teknologi dan dinamika ekonomi yang cepat, harga saham IBM sangat fluktuatif dari waktu ke waktu.

Dalam konteks ini, analisis data deret waktu menjadi pendekatan yang relevan untuk memahami pola historis harga saham dan membangun model peramalan yang akurat. Beberapa metode yang dapat digunakan antara lain adalah metode pemulusan (smoothing), model ARMA/ARIMA, model volatilitas seperti ARCH/GARCH, hingga pendekatan multivariat seperti VAR atau uji kointegrasi. Dengan penerapan metode-metode tersebut, diharapkan dapat diperoleh wawasan lebih dalam terhadap perilaku harga saham IBM.

1.2 Rumusan Masalah

1. Bagaimana karakteristik pola data deret waktu harga saham IBM dari tahun 2020 hingga 2024?
2. Model peramalan deret waktu apa yang paling sesuai untuk memodelkan dan meramalkan harga saham IBM?
3. Apakah terdapat unsur musiman, tren, atau volatilitas yang signifikan dalam data harga saham IBM?
4. Sejauh mana akurasi model yang dibangun dalam memprediksi harga saham di periode mendatang?

1.3 Tujuan Penelitian

1. Menganalisis pola dan karakteristik data deret waktu harga saham IBM.
2. Membangun dan membandingkan beberapa model deret waktu.
3. Mengidentifikasi tren, musiman, dan volatilitas dalam data harga saham.
4. Menentukan model terbaik untuk meramalkan harga saham IBM berdasarkan kriteria evaluasi tertentu

BAB II METODE PENELITIAN

2.1 Variabel Penelitian

Pada project kali, akan digunakan data dari Kaggle yaitu dataset historis harga saham IBM (International Business Machines Corporation). Data ini mencakup periode dari 2 Januari 2020 hingga 29 April 2024, dan disusun dalam format deret waktu harian. Berikut keterangan atau informasi pada dataset:

Variabel	Keterangan
Date	Tanggal perdagangan
Open	Harga pembukaan saham pada hari tersebut
High	Harga tertinggi dalam hari tersebut
Low	Harga terendah dalam hari tersebut
Close	Harga penutupan saham (akhir hari perdagangan)
Adj Close	Harga penutupan yang telah disesuaikan terhadap dividen dan stock split
Volume	Jumlah saham yang diperdagangkan pada hari tersebut

2.2 Pre-Processing

2.2.1 Load Data

```
import pandas as pd
df = pd.read_csv(os.path.join(path, "IBM.csv"))
df
```

	Date	Open	High	Low	Close	Adj Close	Volume
0	2020-01-02	129.063095	129.942642	128.843216	129.464630	105.346336	3293436
1	2020-01-03	127.695984	128.929260	127.686424	128.432129	104.506195	2482890
2	2020-01-06	127.552582	128.336517	127.342255	128.202682	104.319489	2537073
3	2020-01-07	127.810707	129.024857	127.533463	128.288712	104.389488	3232977
4	2020-01-08	128.594650	129.885284	128.030594	129.359467	105.260765	4545916
...	...	...	...	...	...	...	...
1084	2024-04-24	183.169998	184.289993	181.399994	184.100006	184.100006	7616600
1085	2024-04-25	168.199997	172.449997	165.660004	168.910004	168.910004	16702200
1086	2024-04-26	167.500000	167.869995	165.729996	167.130005	167.130005	8983800
1087	2024-04-29	167.399994	168.220001	166.229996	167.429993	167.429993	5242200
1088	2024-04-30	166.490005	166.759995	165.259995	166.199997	166.199997	6011600

2.2.2 Informasi Data


```
[ ] # Melihat informasi umum tentang dataset
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1089 entries, 0 to 1088
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Date        1089 non-null   object
1   Open        1089 non-null   float64
2   High        1089 non-null   float64
3   Low         1089 non-null   float64
4   Close       1089 non-null   float64
5   Adj Close   1089 non-null   float64
6   Volume      1089 non-null   int64
dtypes: float64(5), int64(1), object(1)
memory usage: 59.7+ KB
```

Dataset terdiri dari 1089 observasi dengan 7 kolom. Kolom Date bertipe objek karena memuat informasi tanggal, sedangkan kolom lainnya merupakan numerik bertipe float64 dan int64.

2.2.3 Memeriksa Missing Value

```
# Cek jumlah nilai yang hilang di tiap kolom  
df.isnull().sum()
```



	0
Date	0
Open	0
High	0
Low	0
Close	0
Adj Close	0
Volume	0

Hasilnya menunjukkan bahwa tidak terdapat nilai yang hilang pada seluruh kolom dalam dataset. Ini menunjukkan kualitas data yang baik dan memungkinkan proses pemodelan berjalan tanpa hambatan yang berarti terkait kelengkapan data.

2.3 Metode Analisis

Pada project ini, kami mengajukan tiga metode analisis yaitu ARIMA, SARIMA, dan GARCH.

2.3.1 ARIMA

Model ARIMA (Autoregressive Integrated Moving Average) merupakan salah satu metode peramalan deret waktu yang menggabungkan tiga komponen utama: AR, differencing (I), dan MA. Model ARIMA dengan parameter (p,d,q) secara umum dapat dituliskan sebagai berikut:

$$\Delta^d y_t = c + \sum_{i=1}^p \phi_i \Delta^d y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

2.3.2 SARIMA

Model SARIMA (Seasonal Autoregressive Integrated Moving Average) adalah pengembangan dari ARIMA yang mampu menangani data deret waktu yang memiliki pola musiman (seasonality). Model ini menambahkan komponen musiman ke dalam struktur ARIMA. Notasi umum dari model SARIMA adalah SARIMA(p,d,q)(P,D,Q). Dengan persamaan umum dalam bentuk operator lag (backshift) sebagai berikut:

$$\Phi_P(B^s)\phi_p(B)(1-B)^d(1-B^s)^D y_t = \Theta_Q(B^s)\theta_q(B)\varepsilon_t$$

2.3.3 GARCH

Model GARCH digunakan untuk memodelkan dan meramalkan volatilitas (keragaman atau variasi yang berubah-ubah dari waktu ke waktu) dalam data deret waktu, terutama di bidang keuangan seperti harga saham atau return pasar. Berikut bentuk persamaan umumnya GARCH (p,q):

$$\sigma_{t|t-1}^2 = \alpha_0 + \alpha_1 r_{t-1}^2 + \cdots + \alpha_q r_{t-q}^2 + \beta_1 \sigma_{t-1|t-2}^2 + \cdots + \beta_p \sigma_{t-p|t-2}^2$$

Untuk bentuk jika dilakukan backshift maka modelnya akan sebagai berikut:

$$(1 - \beta_1 B - \cdots - \beta_p B^p) \sigma_{t|t-1}^2 = \alpha_0 + (\alpha_1 B + \cdots + \alpha_q B^q) r_t^2$$

BAB III HASIL DAN PEMBAHASAN

3.1 Exploratory Data Analysis (EDA)

Pertama-tama, akan dilakukan Exploratory Data Analysis (EDA) yang bertujuan untuk memahami karakteristik dataset sebelum melakukan pemodelan dan peramalan lebih lanjut. Pada dataset yang kami miliki, EDA digunakan untuk menggali informasi mengenai pola harga, tren, dan fluktuasi yang ada di dalam data. Proses ini termasuk visualisasi data menggunakan grafik untuk memeriksa distribusi harga penutupan (Adjusted Close), analisis statistik deskriptif seperti mean, median, dan standar deviasi, serta visualisasi data sebelum melakukan pemeriksaan apakah data bersifat stasioner atau tidak.

3.1.1 Mengambil Kolom “Date” dan “Adj.Close” serta Persiapan Data

Pada tahap ini, dibentuk subset dataset IBM yang hanya menggunakan variabel “Date” dan “Adj.Close”. Hal ini dilakukan dengan pertimbangan bahwa tujuan dari analisis kami, yakni melakukan analisis terhadap pergerakan harga saham dan membentuk model serta *forecasting* sesuai. Adjusted close price adalah harga penutupan saham per harinya yang sudah disesuaikan dengan faktor-faktor seperti dividen dan hak-hak pemilik lainnya. Dengan menggunakan harga sesuai Adj.Close, didapat analisis tren dan pergerakan saham yang lebih akurat dengan mempertimbangkan peristiwa-peristiwa yang ada sehingga sangat cocok untuk peramalan jangka panjang.

```
> df_ts <- df[, c("Date", "Adj.Close")]
> df_ts$Date <- as.Date(df_ts$Date)
> df_ts <- ts(df_ts$Adj.Close, frequency = 252, start = c(2020, 1))
> head(df_ts)
Time Series:
Start = c(2020, 1)
End = c(2020, 6)
Frequency = 252
[1] 105.3463 104.5062 104.3195 104.3895 105.2608 106.3732
```

Gambar 3.1.1 Kode transformasi dataset menjadi kolom yang dibutuhkan

Selanjutnya, dilakukan konversi kolom “Date” menjadi format Date sehingga R memproses sebagai tanggal, bukan string dengan fungsi `ts`. Lalu, data dikonversi menjadi objek *time series* agar bisa dilakukan analisis pada platform R. Konversi ini dilakukan dengan membagi data sesuai frekuensi hari *market* saham buka per tahun, yakni sebanyak 252 hari dalam setahun, dimulai dari bulan Januari 2020.

3.1.2 Statistik Deskriptif

```
> summary(df_ts)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  74.49  105.87  119.86  122.55  130.02  197.78
```

Gambar 3.1.2a Statistik deskriptif keseluruhan data

Dapat dilihat bahwa rata-rata nilai adjusted close price pada dataset adalah 122.55, dengan nilai tertinggi 197.78 dan nilai terendah 74.49 sehingga nilai maksimal dan minimal cukup jauh dari rata-rata dan juga kuantil 1 dan 3 data menunjukkan adanya fluktuasi yang signifikan pada *market* saham.

```
> # Mengonversi kembali df_ts menjadi data frame
> df <- data.frame(Date = as.Date(df$Date), Adj.Close = df$Adj.Close)
>
> # Mengelompokkan data berdasarkan tahun, lalu menghitung statistik deskriptif
> df$Year <- format(df$Date, "%Y")
>
> df_yearly <- df %>%
+   group_by(Year) %>%
+   summarise(
+     Min = min(Adj.Close, na.rm = TRUE),
+     Max = max(Adj.Close, na.rm = TRUE),
+     Mean = mean(Adj.Close, na.rm = TRUE),
+     Median = median(Adj.Close, na.rm = TRUE),
+     First.Quartile = quantile(Adj.Close, 0.25, na.rm = TRUE),
+     Third.Quartile = quantile(Adj.Close, 0.75, na.rm = TRUE),
+     SD = sd(Adj.Close, na.rm = TRUE)
+   )
>
> print(df_yearly)
# A tibble: 5 × 8
  Year    Min    Max  Mean Median First.Quartile Third.Quartile    SD
  <chr> <dbl> <dbl> <dbl> <dbl>      <dbl>      <dbl>      <dbl>
1 2020   74.5  122.  99.2  99.2        95.4       102.    7.93
2 2021   97.1  127.  113.  116.       107.       120.    7.77
3 2022  110.  142.  123.  122.       118.       128.    7.58
4 2023  117.  163.  135.  134.       125.       142.   11.9
5 2024  158.  198.  182.  185.       180.       189.  10.9
```


Gambar 3.1.2b Statistik deskriptif data pertahun

Selanjutnya, didapatkan statistik deskriptif data untuk masing-masing tahun. Dapat dilihat bahwa adjusted close price tertinggi terjadi pada tahun 2024 dan terendah pada tahun 2020. Dapat dilihat juga bahwa rata-rata adjusted close price terendah terdapat pada tahun 2020 dan rata-rata tertinggi pada tahun 2024 dengan rata-rata yang terus meningkat seiring tahun. Hal ini dapat mengindikasikan adanya tren pada adjusted close price.

3.1.3 Visualisasi Time Plot

```
# 3.1.3 Visualisasi Time Series
# Konversi df_ts ke data frame
df_ts_df <- data.frame(Date = seq.Date(from = as.Date("2020-01-01"), by = "days", length.out = length(df_ts)),
  Adj.Close = as.numeric(df_ts))

# Plot setelah konversi ke data frame
ggplot(df_ts_df, aes(x = Date, y = Adj.Close)) +
  geom_line(color = "blue") +
  labs(title = "Harga Adjusted Close IBM Stock Seiring Waktu", x = "Tahun", y = "Adjusted Closing Price") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




Gambar 3.1.3 Visualisasi Time Plot untuk adjusted close price saham IBM

Melalui time plot di atas, didapat bahwa saham IBM menunjukkan penurunan yang cukup tajam di pertengahan tahun 2020 mengingat terjadinya peristiwa pandemi, lalu menunjukkan tren peningkatan dan naik signifikan di tahun 2024 awal akibat pemulihan pasca pandemi, dan kembali menurun di pertengahan tahun. Jika dengan istilah saham, dapat dikatakan bahwa terdapat siklus bullish pada pertengahan tahun 2020 menuju 2021 dan terdapat siklus bearish pada pertengahan tahun 2024.

3.1.4 Visualisasi Distribusi Harga Adjusted Close

```
# 3.1.4 | Visualisasi distribusi harga 'Open' dan 'Close' menggunakan histogram
ggplot(df_ts_df, aes(x = Adj.Close)) +
  geom_histogram(bins = 30, fill = "red", color = "black", alpha = 0.7) +
  labs(title = "Distribusi Adjusted Close Prices", x = "Close Price", y = "Frequency") +
  theme_minimal()
```




Gambar 3.1.4 Histogram dari Adjusted Close Price

Dari histogram, terlihat bahwa harga adjusted close berdistribusi paling banyak di harga 120-140. Terlihat pula bahwa terdapat penyimpangan ekstrim, yakni harga 80 dan 200 yang bernilai sangat jauh dari pusat data dengan frekuensi yang sedikit pula. Selain itu, terlihat juga bahwa terdapat lebih dari satu puncak adjusted close price menunjukkan bahwa adanya multimodal.

3.1.5 Visualisasi Volatilitas Data

```
# Boxplot tahunan
ggplot(df, aes(x = Year, y = Adj.Close)) +
  geom_boxplot(fill = "lightblue", color = "black") +
  labs(title = "Distribusi Harga Adjusted Close IBM Stock per Tahun", x = "Tahun", y = "Harga Adjusted Close") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




Gambar 3.1.5a Box Plot Tahunan Harga Adjusted Close

Dari grafik distribusi harga adjusted close saham IBM per tahun terlihat bahwa harga mengalami fluktuasi yang cukup signifikan dari tahun ke tahun. Harga mencapai puncaknya sekitar 175-200 di tahun tertentu (kemungkinan 2021-2022), kemudian menurun drastis hingga kisaran 75-100 di periode lainnya (mungkin 2020 atau 2023-2024), menunjukkan volatilitas yang tinggi dengan pola naik-turun yang tajam dalam rentang waktu 4-5 tahun terakhir.

```
# Menghitung standar deviasi per tahun untuk volatilitas
volatility_per_year <- df %>%
  group_by(Year) %>%
  summarise(Volatility = sd(Adj.Close))

# Plot volatilitas per tahun
ggplot(volatility_per_year, aes(x = Year, y = Volatility)) +
  geom_bar(stat = "identity", fill = "lightblue") +
  labs(title = "Volatilitas Harga Adjusted Close IBM Stock per Tahun", x = "Tahun", y = "Standar Deviasi (Volatilitas)") +
  theme_minimal()
```



Gambar 3.1.5b Volatility Plot untuk harga Adjusted Close

Dari plot volatilitas harga adjusted close saham IBM, terlihat bahwa standar deviasi (volatilitas) menunjukkan pola fluktuasi yang bervariasi setiap tahunnya, di mana tahun 2021-2022 kemungkinan mengalami puncak volatilitas tertinggi (ditandai dengan lonjakan signifikan pada grafik), mencerminkan ketidakpastian pasar yang ekstrem selama periode tersebut, sementara tahun 2020 dan 2023-2024 menunjukkan volatilitas yang relatif lebih rendah, mengindikasikan periode yang lebih stabil meskipun dengan tren harga yang tetap fluktuatif.

3.2 Uji Stasioneritas Runtun Waktu

Selanjutnya, dilakukan uji stasioneritas terhadap *time series* yang dimiliki pada *df_ts*. Akan dilakukan uji stasioneritas dengan tujuan untuk memeriksa apakah data *time series* tersebut memiliki sifat yang stasioner, yakni memiliki rata-rata, varians, dan kovarians yang tidak berubah sepanjang waktu. Uji stasioneritas sangatlah penting terutama dalam menentukan pemodelan ARIMA dan GARCH yang akan dilakukan kelak. Uji stasioneritas akan dilakukan menggunakan uji Augmented Dickey-Fuller (ADF), dekomposisi *time series*, dan plot ACF.

3.2.1 Dekomposisi time series


Dekomposisi time series adalah proses yang digunakan untuk memecah data time series menjadi komponen-komponen yang lebih sederhana, yaitu komponen tren , musiman (seasonality), dan residual (noise). Tujuan dari dekomposisi adalah untuk mempermudah pemahaman dan analisis data dengan mengidentifikasi pola yang mendasarinya. Komponen tren menggambarkan arah jangka panjang dari data, apakah meningkat atau menurun seiring waktu. Musiman menunjukkan fluktuasi yang terjadi secara periodik pada interval waktu tertentu, seperti perubahan harga yang terjadi setiap bulan atau setiap tahun. Sedangkan residual adalah bagian yang tidak dapat dijelaskan oleh tren atau musiman. Model dari dekomposisi *time series* adalah:

$$Y_t = T_t + S_t + R_t$$

dengan Y_t adalah nilai asli time series pada waktu t , T_t adalah komponen tren pada waktu t , S_t adalah komponen seasonal pada waktu t , dan R_t adalah residual pada waktu t .

```
# Decompose time series
decomposed_data <- decompose(df_ts)

# Plot hasil dekomposisi
plot(decomposed_data)
```



Gambar 3.2.1 Plot Dekomposisi time series

Melalui plot dekomposisi tersebut, kita dapat melihat dengan lebih jelas tren yang terjadi pada data. Terlihat dengan sangat jelas bahwa data meningkat seiring waktu terlihat dari plot “trend” pada plot dekomposisi. Dengan demikian, tren naik menunjukkan bahwa data tidak konstan sepanjang waktu atau terdapat peningkatan nilai rata-rata atau mean seiring dengan bertambahnya waktu. Maka dapat ditarik kesimpulan sementara bahwa data tidak stasioner.

3.2.2 Uji Augmented Dickey-Fuller (ADF)

Uji Augmented Dickey-Fuller (ADF) adalah uji statistik yang digunakan untuk menguji keberadaan unit root dalam sebuah *time series*, yang merupakan indikasi dari tidak stasioner. Uji ADF menguji hipotesis nol (H_0) bahwa time series memiliki unit root, yang berarti data tersebut tidak stasioner. Maka:

H_0 : Data *time series* tidak stasioner

H_1 : Data *time series* stasioner

Jika p-value dari uji ADF lebih kecil dari tingkat signifikansi yang ditentukan (pada tes ini = 0.05), maka hipotesis nol ditolak, yang menunjukkan bahwa data tersebut stasioner. Sebaliknya, jika p-value lebih besar, maka tidak ada cukup bukti untuk menolak hipotesis nol, yang menunjukkan bahwa data tidak stasioner dan perlu dilakukan transformasi (differencing) agar menjadi stasioner.

```
> # Uji ADF untuk kolom Adj.Close
> adf_test <- adf.test(df$Adj.Close, alternative = "stationary")
>
> # Tampilkan hasil uji ADF
> print(adf_test)
```

Augmented Dickey-Fuller Test

data: df\$Adj.Close
Dickey-Fuller = -3.1777, Lag order = 10, p-value =
0.09176
alternative hypothesis: stationary


Gambar 3.2.2 Hasil Uji ADF

Dengan menggunakan tingkat signifikansi $\alpha = 0.05$, didapat berdasar output R bahwa p-value = 0.09176 > 0.05 sehingga H_0 gagal ditolak. Dengan demikian, dapat disimpulkan bahwa pada tingkat kepercayaan 95%, data *time series* belum stasioner.

3.2.3 Plot ACF

Autocorrelation Function (ACF) adalah metode yang digunakan untuk mengukur hubungan antara nilai-nilai dalam *time series* yang terpisah oleh sejumlah lag waktu tertentu. ACF menghitung seberapa kuat hubungan antara data pada waktu t dan data pada waktu $t-k$, di mana k adalah lag yang digunakan. Nilai ACF berkisar antara -1 hingga 1, di mana nilai mendekati 1 menunjukkan korelasi positif yang kuat, dan nilai mendekati -1 menunjukkan

korelasi negatif yang kuat. ACF digunakan untuk melihat pola dalam data, seperti tren atau siklus, serta untuk menentukan model yang tepat untuk analisis time series.



Gambar 3.2.3 Plot ACF

Terlihat bahwa nilai ACF menurun secara konstan namun tidak mencapai nilai nol secara signifikan, bahkan masih mendekati 1 pada lag yang lebih tinggi. Hal ini mengindikasikan adanya ketergantungan jangka panjang antar nilai data. Hal ini sering menunjukkan bahwa data tersebut tidak stasioner, karena untuk data yang stasioner, ACF seharusnya menurun secara cepat dan tidak ada pola jangka panjang yang tersisa. Kondisi ini memperkuat bahwa uji yang telah dilakukan bahwa *time series* memiliki tren yang perlu dihilangkan terlebih dahulu sebelum bisa dilakukan analisis lebih lanjut.

3.3 Differencing Data Time Series

```
> # 3.3 Data tdk stasioner shg dilakukan differencing
> df_ts_diff <- diff(df_ts, differences = 1)
>
> adf_test_diff <- adf.test(df_ts_diff, alternative = "stationary")
Warning message:
In adf.test(df_ts_diff, alternative = "stationary") :
  p-value smaller than printed p-value
> print(adf_test_diff)
```

Augmented Dickey-Fuller Test

```
data: df_ts_diff
Dickey-Fuller = -8.9113, Lag order = 10, p-value = 0.01
alternative hypothesis: stationary
```

Gambar 3.3 Transformasi data time series agar stasioner

Selanjutnya, dilakukan differencing data sebanyak sekali untuk membentuk data yang stasioner. Differencing dengan orde satu secara matematis digambarkan sebagai:

$$\Delta y_t = y_t - y_{t-1}$$



Teknik differencing dapat menghilangkan tren sehingga data lebih stasioner dan siap dilakukan analisis lanjutan. Dilakukan diagnostik data kembali setelah differencing dan didapat hasil uji Augmented Dickey-Fuller (ADF) dengan nilai Dickey-Fuller sebesar -8.9113 dan p-value sebesar 0.01. Nilai p-value yang lebih kecil dari 0.05 ini mengindikasikan bahwa kita dapat menolak hipotesis nol (yang menyatakan bahwa data memiliki akar unit dan tidak stasioner). Dengan demikian, hasil ini menunjukkan bahwa setelah dilakukan differencing, data menjadi stasioner dan siap untuk analisis lebih lanjut. Differencing berhasil menghilangkan komponen tren dalam data, yang sebelumnya menunjukkan ketidakstasioneran.

3.3 Spesifikasi Model


Pada tahap ini, akan dilakukan proses identifikasi model ARIMA, SARIMA, dan GARCH terhadap data ini. Tujuan dari spesifikasi model adalah menentukan bentuk matematis model peramalan yang paling sesuai dengan karakteristik data, sebelum dilakukan estimasi parameter.

3.3.1 Model ARIMA

Model ARIMA dibangun atas dasar data *adjusted close* yang telah ditransformasi menjadi runtun waktu harian. Sebelumnya, Uji Augmented Dickey-Fuller (ADF) terhadap data asli menunjukkan bahwa data belum stasioner (p-value > 0.05), sehingga dilakukan differencing satu kali. Setelah differencing pertama, hasil uji ADF menunjukkan bahwa data telah stasioner (p-value < 0.05), sehingga nilai differencing $d = 1$.



Untuk mengidentifikasi nilai parameter ARIMA(p,d,q), dilakukan analisis terhadap plot ACF dan PACF dari data hasil differencing, serta bantuan tabel EACF. Perhatikan ketiga



Berdasarkan pola ACF yang cut-off pada lag ke-1 dan PACF, serta hasil EACF, maka diajukan model awal yaitu ARIMA(1,1,1). Selain model tersebut, diajukan juga model lain yaitu ARIMA(2,1,0) dan ARIMA(0,1,2).

Selanjutnya, akan dilihat fitting setiap model untuk membandingkan nilai AIC dan BIC sehingga dapat diambil model yang terbaik.

1. ARIMA(1,1,1)

```
> summary(model_111)
Series: data_ts
ARIMA(1,1,1)

Coefficients:
          ar1      ma1
      -0.2268  0.1948
s.e.    0.5435  0.5445

sigma^2 = 3.964: log likelihood = -2292.09
AIC=4590.17 AICc=4590.19 BIC=4605.15

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.05750879 1.988337 1.333544 0.02749361 1.13651 0.07467954 0.0007482618
```

2. ARIMA(2,1,0)

```
> summary(model_210)
Series: data_ts
ARIMA(2,1,0)

Coefficients:
          ar1      ar2
      -0.0304  0.0159
s.e.    0.0303  0.0303

sigma^2 = 3.964: log likelihood = -2292.02
AIC=4590.04 AICc=4590.06 BIC=4605.02

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.05680743 1.98822 1.333643 0.02715006 1.136427 0.07468507 -0.0009455362
```

3. ARIMA(0,1,2)

```
> summary(model_012)
Series: data_ts
ARIMA(0,1,2)

Coefficients:
      ma1      ma2
    -0.0305  0.0171
s.e.    0.0303  0.0303

sigma^2 = 3.964: log likelihood = -2292.02
AIC=4590.03  AICc=4590.06  BIC=4605.01


Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.05675701 1.988212 1.333622 0.02712576 1.136423 0.07468391 -0.0008532525
```

```
> AIC(model_111, model_210, model_012)
      df      AIC
model_111  3 4590.170
model_210  3 4590.042
model_012  3 4590.034
> BIC(model_111, model_210, model_012)
      df      BIC
model_111  3 4605.147
model_210  3 4605.019
model_012  3 4605.010
```

Dari ketiga output summary model tersebut, kita bisa membandingkan nilai AIC dan BIC nya. Terlihat bahwa model ARIMA(0,1,2) mempunyai nilai AIC dan BIC paling rendah di antara ketiganya, yaitu sebesar 4590.03 dan 4605.01 . Sehingga, model ARIMA paling baik yang akan diajukan adalah ARIMA(0,1,2).

3.3.2 Model SARIMA

Untuk mengakomodasi kemungkinan pola musiman dalam data harian, dilakukan eksplorasi model musiman ARIMA(SARIMA). Sebelumnya, perhatikan plot ACF dengan lag musiman berikut ini.



Berdasarkan grafik ini, sebenarnya kita tidak perlu untuk mempertimbangkan komponen musiman dalam model ARIMA yang ingin diajukan. Hal ini disebabkan dalam grafik tersebut nilai ACF menurun secara bertahap dan eksponensial tanpa pola berulang. Kemudian, tidak ada spike signifikan pada lag tertentu yang berulang secara periodik. Namun, akan tetap ditinjau untuk model musiman ARIMA ini.

Akan diajukan model $ARIMA(0,1,2) \times (1,0,1)_{21}$. Berikut summary untuk model ini

```
> summary(sarima_model)
Series: data_ts
ARIMA(0,1,2)(1,0,1)[21]

Coefficients:
      ma1      ma2      sar1      sma1
    -0.0295  0.0167  -0.0889  0.0984
s.e.    0.0305  0.0303   1.0031  0.9959

sigma^2 = 3.971:  log likelihood = -2291.97
AIC=4593.94  AICc=4594  BIC=4618.9

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.05604279 1.988126 1.333596 0.0267533 1.136364 0.07468246 -0.000830188
```

Dapat diperhatikan bahwa hasil estimasi model ini memberikan nilai AIC sebesar 4593.94 dan nilai BIC sebesar 4618.9, yang lebih tinggi daripada model $ARIMA(0,1,2)$,

sehingga tidak dipilih sebagai model terbaik dan ARIMA(0,1,2) tetap menjadi model yang diajukan.

3.3.3 Model GARCH

Selain pendekatan ARIMA dan SARIMA, model GARCH juga dipertimbangkan dalam pemodelan data return saham, mengingat karakteristik volatilitas yang tinggi dan bersifat tidak konstan pada data keuangan. Model GARCH (Generalized Autoregressive Conditional Heteroskedasticity) sangat cocok digunakan ketika variansi residual menunjukkan adanya efek heteroskedastisitas bersyarat, yaitu fluktuasi besar dan kecil yang terjadi secara berkelompok (*volatility clustering*).

Untuk membangun model GARCH, terlebih dahulu dilakukan transformasi data *adjusted close* menjadi return log harian sebagai berikut :

```
# Hitung return log harian dari Adj Close
data$log_return <- c(NA, diff(log(data$Adj.Close)))
```

Return log ini kemudian digunakan sebagai input pada model GARCH(1,1) dengan fungsi mean yang mengikuti model ARMA(1,1). Model ini kemudian dilakukan fitting menggunakan fungsi “ugarchfit” dari paket “ugarch” di R. Perhatikan summary nya sebagai berikut

```
*-----*
*          GARCH Model Fit          *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : sGARCH(1,1)
Mean Model       : ARFIMA(1,0,1)
Distribution      : norm

Optimal Parameters
-----
      Estimate Std. Error t value Pr(>|t|)
mu      0.000487   0.000462   1.0537 0.292009
ar1     -0.901765   0.051952 -17.3575 0.000000
ma1      0.939670   0.039868  23.5695 0.000000
omega    0.000029   0.000008   3.8388 0.000124
alpha1   0.096286   0.023645   4.0722 0.000047
beta1    0.798533   0.044144  18.0894 0.000000

Robust Standard Errors:
      Estimate Std. Error t value Pr(>|t|)
mu      0.000487   0.000512   0.95221 0.340988
ar1     -0.901765   0.051124 -17.63867 0.000000
ma1      0.939670   0.040134  23.41332 0.000000
omega    0.000029   0.000011   2.77101 0.005588
alpha1   0.096286   0.049008   1.96470 0.049450
beta1    0.798533   0.060273  13.24853 0.000000

LogLikelihood : 2978.947

Information Criteria
-----
Akaike      -5.4650
Bayes       -5.4374
Shibata     -5.4650
Hannan-Quinn -5.4546
```

Dari output summary tersebut, didapatkan nilai AIC dan BIC per observasi berturut-turut adalah -5.4650 dan -5.4374 . Sehingga, untuk mendapatkan nilai AIC dan BIC untuk model GARCH ini, cukup dikalikan dengan jumlah observasi nya yaitu sebanyak 1088 data return harian dan didapatkan nilai AIC dan BIC nya berturut-turut adalah -5945.42 dan -5915.891 . Model ini juga menunjukkan bahwa variansi residual bersifat stasioner secara varians, dengan nilai $\alpha_1 + \beta_1 = 0.096286 + 0.798533 = 0.8948 < 1$.

Kesimpulan

Perhatikan bahwa model GARCH(1,1) memiliki nilai AIC dan BIC yang paling rendah dari semua model yang diajukan. Oleh karena itu, GARCH(1,1) adalah model terbaik yang akan diajukan untuk memodelkan perilaku return saham IBM.

3.4 Estimasi Parameter

Model GARCH(1,1) dengan fungsi mean ARMA(1,1) yang telah dipilih sebelumnya akan diestimasi parameternya menggunakan metode Maximum Likelihood Estimation (MLE) melalui fungsi `ugarchfit` dalam software R. Proses estimasi dilakukan terhadap data return log harian saham IBM yang telah dihitung dari harga *adjusted close*. Hasil estimasi parameter dapat dilihat dari output summary sebagai berikut

Optimal Parameters				
	Estimate	Std. Error	t value	Pr(> t)
mu	0.000487	0.000462	1.0537	0.292009
ar1	-0.901765	0.051952	-17.3575	0.000000
ma1	0.939670	0.039868	23.5695	0.000000
omega	0.000029	0.000008	3.8388	0.000124
alpha1	0.096286	0.023645	4.0722	0.000047
beta1	0.798533	0.044144	18.0894	0.000000

Dari output tersebut, kita bisa menginterpretasikan beberapa hal. Pertama, untuk Mean equation, nilai $\phi_1 = -0.901765$ menunjukkan bahwa return harian memiliki pengaruh negatif yang cukup kuat dari nilai sebelumnya. Lalu, koefisien $\theta_1 = 0.939670$ menunjukkan adanya efek shock dari masa lalu yang signifikan. Kemudian, meskipun μ tidak signifikan, hal ini umum terjadi dalam data return log keuangan yang sering berfluktuasi di sekitar nol. Kedua, untuk Variance equation, parameter $\omega = 0.000029$ adalah varians dasar atau long-run volatility yang kecil. Lalu, parameter $\alpha_1 = 0.0963$ menunjukkan reaksi varians terhadap shock baru. Kemudian, parameter $\beta_1 = 0.798533$ menunjukkan persistensi varians masa lalu. Model ini juga menunjukkan bahwa variansi residual bersifat stasioner secara varians, dengan nilai $\alpha_1 + \beta_1 = 0.096286 + 0.798533 = 0.8948 < 1$.

Sehingga, persamaan untuk GARCH(1,1) ini adalah:

Persamaan Mean (ARMA(1,1)) :

$$r_t = \mu + \phi_1 r_{t-1} + \theta_1 \varepsilon_{t-1} + \varepsilon_t$$

$$r_t = 0.000487 - 0.9018r_{t-1} + 0.9397\varepsilon_{t-1} + \varepsilon_t$$

Persamaan Varians :

$$\varepsilon_t = z_t \cdot \sqrt{h_t}, \quad z_t \sim N(0, 1)$$

$$h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 h_{t-1}$$

$$h_t = 0.000029 + 0.096286\varepsilon_{t-1}^2 + 0.798533h_{t-1}$$

Uji Signifikansi Estimasi Parameter

Perhatikan output berikut ini

Optimal Parameters

	Estimate	Std. Error	t value	Pr(> t)
mu	0.000487	0.000462	1.0537	0.292009
ar1	-0.901765	0.051952	-17.3575	0.000000
ma1	0.939670	0.039868	23.5695	0.000000
omega	0.000029	0.000008	3.8388	0.000124
alpha1	0.096286	0.023645	4.0722	0.000047
beta1	0.798533	0.044144	18.0894	0.000000

Robust Standard Errors:

	Estimate	Std. Error	t value	Pr(> t)
mu	0.000487	0.000512	0.95221	0.340988
ar1	-0.901765	0.051124	-17.63867	0.000000
ma1	0.939670	0.040134	23.41332	0.000000
omega	0.000029	0.000011	2.77101	0.005588
alpha1	0.096286	0.049008	1.96470	0.049450
beta1	0.798533	0.060273	13.24853	0.000000

Dari output di atas, dapat disimpulkan bahwa seluruh parameter kecuali konstanta rata-rata (μ) signifikan secara statistik pada taraf signifikansi 5%. Parameter μ memiliki nilai p sebesar 0.341, yang menunjukkan bahwa nilai rata-rata return log harian mendekati nol dan tidak berbeda signifikan dari nol. Hal ini umum terjadi pada data keuangan. Parameter ω , α_1 , dan β_1 yang signifikan menunjukkan bahwa model GARCH(1,1) mampu menjelaskan dinamika volatilitas dalam data dengan baik.

3.5 Model Diagnostik

3.5.1 analisis residual (white noise)

1.1. Uji Ljung box

```
> Box.test(model_012$residuals, lag = 20, type = "Ljung-Box")

Box-Ljung test

data: model_012$residuals
X-squared = 27.141, df = 20, p-value = 0.1313

> Box.test((model_012$residuals)^2, lag = 20, type = "Ljung-Box")

Box-Ljung test

data: (model_012$residuals)^2
X-squared = 42.346, df = 20, p-value = 0.002493
```

P-value residual = 0.1313 > 0.05 menunjukkan bahwa tidak terdapat autokorelasi signifikan pada residual model ARIMA(0,1,2). Artinya, model telah cukup baik dalam menangkap dinamika pada nilai tengah (mean) data.

Box-Ljung Test pada residual² juga menunjukkan Statistik $X^2 = 42.346$, $df = 20$, $p\text{-value} = 0.002493$. Yang membuktikan adanya autokorelasi yang signifikan pada residual kuadrat, yang menandakan keberadaan efek heteroskedastisitas (ARCH effect) yang belum tertangkap oleh model ARIMA. Dengan kata lain, model ARIMA(0,1,2) belum mampu menangkap dinamika volatilitas data secara memadai.

```
> Box.test(resid, lag = 20, type = "Ljung-Box")

Box-Ljung test

data: resid
X-squared = 9.9936, df = 20, p-value = 0.9683

> Box.test(resid^2, lag = 20, type = "Ljung-Box")

Box-Ljung test

data: resid^2
X-squared = 2.8193, df = 20, p-value = 1
```

Uji Ljung-Box dilakukan terhadap residual untuk mengetahui apakah masih terdapat autokorelasi yang tersisa. Hasil uji Ljung-Box pada residual menunjukkan **p-value = 0.9683**. Dengan p-value yang jauh lebih besar dari 0.05, maka **H_0 (tidak ada autokorelasi)** gagal ditolak. Artinya, **tidak terdapat autokorelasi yang signifikan pada residual model**, sehingga model telah cukup baik dalam menangkap dinamika nilai tengah (*mean*) data.

Selanjutnya, juga dilakukan pada residual yang dikuadratkan untuk mengevaluasi keberadaan pola pada volatilitas (varian residual). Hasil uji menunjukkan **p-value = 1**. P-value sebesar 1 menunjukkan **tidak ada autokorelasi signifikan pada varians residual**,

yang berarti model GARCH telah berhasil mengatasi efek heteroskedastisitas dalam data. Model GARCH(1,1) terbukti memadai dalam mengatasi autokorelasi pada residual dan juga dalam menghilangkan efek ARCH/heteroskedastisitas.

1.2. Uji Normalitas residual

Ho : residual berdistribusi normal

H1 : tidak demikian

```
> shapiro.test(model_012$residuals)

      Shapiro-Wilk normality test

data:  model_012$residuals
W = 0.89034, p-value < 2.2e-16

> jarque.bera.test(model_012$residuals)

      Jarque Bera Test

data:  model_012$residuals
X-squared = 5895.6, df = 2, p-value < 2.2e-16

> jarque.bera.test(resid)

      Jarque Bera Test

data:  resid
X-squared = 4796.9, df = 2, p-value < 2.2e-16
```

Pengujian normalitas residual dilakukan menggunakan Shapiro-Wilk test dan Jarque-Bera test. Hasil pengujian menunjukkan bahwa p-value jauh di bawah 0.05, maka H_0 (residual berdistribusi normal) ditolak, sehingga dapat disimpulkan bahwa residual model ARIMA(0,1,2) dan GARCH(1,1) tidak berdistribusi normal.

1.3. Uji ARCH effect sisa untuk model GARCH

Untuk menguji apakah terdapat gejala heteroskedastisitas (variasi residual yang tidak konstan) dalam bentuk efek ARCH (Autoregressive Conditional Heteroskedasticity), digunakan ARCH-LM Test terhadap residual yang telah dikuadratkan. Hasil pengujian sebagai berikut:

```
> ArchTest(resid^2, lags = 10)

      ARCH LM-test; Null hypothesis: no ARCH effects

data:  resid^2
Chi-squared = 0.40244, df = 10, p-value = 1
```

Karena p-value jauh di atas 0.05, maka H_0 (tidak terdapat efek ARCH) gagal ditolak. Dengan demikian, tidak terdapat indikasi efek ARCH pada residual model ARIMA(0,1,2).

3.5.2 Overfitting

Split data, untuk data train dan test

```
n_ts <- length(data_ts)
train_size <- round(0.8 * n_ts)
train_data <- data_ts[1:train_size]
test_data <- data_ts[(train_size + 1):n_ts]
```

Data train dilakukan ulang ke model yang diajukan, yaitu ARIMA(0,1,2) dan GARCH(1,1)

```
model_train012 <- Arima(train_data, order = c(0, 1, 2))
forecast_012 <- forecast(model_train012, h = length(test_data))
error_arima012 <- test_data - forecast_012$mean
mape_arima012 <- mean(abs(error_arima012 / test_data)) * 100

spec <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1,1)),
  mean.model      = list(armaOrder = c(1,1), include.mean = TRUE),
  distribution.model = "norm"
)
fit_garch <- ugarchfit(spec, data = train_data)
forecast_garch <- ugarchforecast(fit_garch, n.ahead = length(test_data))
mean_forecast <- fitted(forecast_garch)
error_garch <- test_data - mean_forecast
mape_garch <- mean(abs(error_garch / test_data)) * 100
```

Selanjutnya akan dibandingkan hasil Mean Absolute Percentage Error (MAPE) dari kedua model.

```
> cat("MAPE ARIMA(0,1,2):", round(mape_arima012, 2), "%\n")
MAPE ARIMA(0,1,2): 14.63 %
> cat("MAPE GARCH(1,1):", round(mape_garch, 2), "%\n")
MAPE GARCH(1,1): 22.31 %
```

Evaluasi overfitting dilakukan dengan membandingkan performa model pada data pelatihan dan pengujian menggunakan metrik MAPE. Hasil menunjukkan bahwa model ARIMA(0,1,2) memiliki nilai MAPE sebesar 14.63%, sedangkan model GARCH(1,1) menghasilkan MAPE sebesar 22.31%. Berdasarkan nilai tersebut, model ARIMA lebih mampu melakukan generalisasi terhadap data baru dan tidak menunjukkan indikasi overfitting yang signifikan, sementara GARCH(1,1) menunjukkan performa prediksi yang lebih lemah pada data uji, sehingga diduga mengalami overfitting atau ketidaksesuaian dengan pola data mean.

1. Banding model ARIMA dan GARCH terbaik dengan model yang lebih kompleks

akan diajukan 4 model overfit, yaitu:

- ARIMA(1,1,2)

- ARIMA(0,1,3)

```
#MODEL OVERFIT ARIMA
model_arima112 <- Arima(train_data, order = c(1,1,2))
res_arima112 <- residuals(model_arima112)
model_arima013 <- Arima(train_data, order = c(0,1,3))
res_arima013 <- residuals(model_arima013)

> AIC(model_train012, model_arima112, model_arima013)
      df      AIC
model_train012  3 3601.935
model_arima112  4 3603.716
model_arima013  4 3603.290
> BIC(model_train012, model_arima112, model_arima013)
      df      BIC
model_train012  3 3616.241
model_arima112  4 3622.790
model_arima013  4 3622.364
```

Dapat dilihat dari output AIC dan BIC di atas bahwa model ARIMA(0,1,2) masih lebih baik daripada model ARIMA(1,1,2) maupun ARIMA(0,1,3).

3.5.3 Forecasting

```

*-----*
*          GARCH Model Forecast          *
*-----*
Model: sGARCH
Horizon: 10
Roll Steps: 0
Out of Sample: 0


0-roll forecast [T0=1088-01-01]:
      Series      Sigma
T+1  0.0025034  0.02304
T+2 -0.0013311  0.02246
T+3  0.0021268  0.02192
T+4 -0.0009914  0.02142
T+5  0.0018204  0.02097
T+6 -0.0007152  0.02056
T+7  0.0015714  0.02018
T+8 -0.0004906  0.01984
T+9  0.0013688  0.01952
T+10 -0.0003079 0.01924

```


```

> print(forecast_df)
   step_ahead mean_return_forecast volatility_forecast
1           1          0.0025034382          0.02304319
2           2         -0.0013310797          0.02245533
3           3          0.0021267527          0.02191594
4           4         -0.0009913981          0.02142178
5           5          0.0018204398          0.02096972
6           6         -0.0007151760          0.02055678
7           7          0.0015713525          0.02018011
8           8         -0.0004905579          0.01983700
9           9          0.0013687999          0.01952487
10          10         -0.0003079031          0.01924127

```



untuk ARIMA(0,1,2)



```
> print(forecast_df)
   time forecast lower_80 upper_80 lower_95 upper_95
1  5.321429  166.2442  163.6927  168.7957  162.3420  170.1464
2  5.325397  166.2241  162.6703  169.7779  160.7890  171.6592
3  5.329365  166.2241  161.8690  170.5792  159.5636  172.8846
4  5.333333  166.2241  161.1938  171.2544  158.5309  173.9173
5  5.337302  166.2241  160.5990  171.8492  157.6213  174.8269
5  5.341270  166.2241  160.0614  172.3868  156.7991  175.6491
7  5.345238  166.2241  159.5671  172.8811  156.0431  176.4051
3  5.349206  166.2241  159.1070  173.3412  155.3394  177.1088
9  5.353175  166.2241  158.6749  173.7733  154.6786  177.7696
10 5.357143  166.2241  158.2662  174.1820  154.0536  178.3946
```

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan hasil analisis data deret waktu harga saham IBM dan evaluasi terhadap berbagai model yang telah diujikan, diperoleh bahwa model yang paling tepat digunakan adalah model GARCH(1,1). Model ini dipilih karena mampu menangkap karakteristik paling dominan dalam data finansial, yaitu volatilitas yang tidak konstan dari waktu ke waktu. Dengan demikian, model GARCH(1,1) tidak hanya lebih akurat dalam merepresentasikan struktur data, tetapi juga memberikan informasi penting mengenai risiko dan ketidakpastian yang melekat pada pergerakan harga saham. Oleh karena itu, model ini dinilai paling sesuai untuk digunakan dalam peramalan dan analisis risiko terhadap data harga saham IBM dalam proyek ini.

Jika tujuan utama dari analisis ini adalah untuk memperoleh hasil peramalan nilai yang akurat, maka model ARIMA(0,1,2) dinilai lebih baik dibandingkan model lainnya. Hal ini didasarkan pada kriteria evaluasi yang lebih rendah, yang menunjukkan performa prediksi yang lebih stabil dan presisi. Meskipun model GARCH unggul dalam menangkap dinamika volatilitas, ARIMA(0,1,2) lebih sesuai apabila fokus utamanya adalah akurasi dalam memproyeksikan nilai masa depan.

4.2 Saran

Berdasarkan hasil analisis, disarankan agar pemilihan model disesuaikan dengan tujuan utama penelitian. Jika fokusnya adalah memodelkan volatilitas dan memahami risiko pergerakan harga saham, maka model GARCH(1,1) lebih tepat digunakan. Namun, jika tujuan utamanya adalah menghasilkan peramalan nilai yang akurat, maka model ARIMA(0,1,2) lebih direkomendasikan karena memberikan hasil prediksi yang lebih stabil dan presisi. Ke depannya, penggunaan kombinasi model juga dapat dipertimbangkan untuk menangkap pola tren sekaligus volatilitas.

LAMPIRAN

Link Google Drive :

 Final Project Metode Peramalan