

**LAPORAN TUGAS AKHIR ANALISIS MULTIVARIAT:  
ANALISIS KLASSTERING, ANALISIS REGRESI MULTIVARIAT,  
DAN ANALISIS KORESPONDENSI BERGANDA**



**DISUSUN OLEH KELOMPOK 5:**

|                                  |            |
|----------------------------------|------------|
| Darryl Jetro Hezekia Sinaga      | 2306249722 |
| Jaka Satria Gumilang             | 2306249735 |
| Riandika Rafael Jaya Pangaribuan | 2306242874 |

**DEPARTEMEN MATEMATIKA  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
UNIVERSITAS INDONESIA  
TAHUN AJARAN 2024/2025**

**TABEL KONTRIBUSI**

| <b>Nama</b>                      | <b>NPM</b> | <b>Kontribusi</b>                                                                                               | <b>Tingkat Kontribusi</b> |
|----------------------------------|------------|-----------------------------------------------------------------------------------------------------------------|---------------------------|
| Darryl Jetro Hezekia Sinaga      | 2306249722 | Mengerjakan bagian pendahuluan dan analisis klastering terhadap data                                            | 100%                      |
| Jaka Satria Gumilang             | 2306249735 | Mengerjakan bagian preprocessing data, analisis deskriptif data, dan analisis regresi multivariat terhadap data | 100%                      |
| Riandika Rafael Jaya Pangaribuan | 2306242874 | Mengerjakan bagian analisis korespondensi berganda terhadap data dan bagian penutup                             | 100%                      |

## DAFTAR ISI

|                                                                              |           |
|------------------------------------------------------------------------------|-----------|
| <b>TABEL KONTRIBUSI.....</b>                                                 | <b>2</b>  |
| <b>DAFTAR ISI.....</b>                                                       | <b>3</b>  |
| <b>BAB I PENDAHULUAN.....</b>                                                | <b>4</b>  |
| 1.1 Latar Belakang.....                                                      | 4         |
| 1.2 Rumusan Masalah.....                                                     | 4         |
| 1.3 Tujuan Penelitian.....                                                   | 5         |
| 1.4 Informasi Dataset.....                                                   | 5         |
| <b>BAB 2 PREPROCESSING.....</b>                                              | <b>8</b>  |
| <b>2.1 Informasi Data.....</b>                                               | <b>8</b>  |
| <b>BAB 3 ANALISIS.....</b>                                                   | <b>18</b> |
| 3.1 Analisis Klastering.....                                                 | 18        |
| 3.1.1 Klastering Hieararki.....                                              | 18        |
| Selanjutnya, dilakukan transformasi variabel ke bentuk jarak euclidean:..... | 18        |
| 3.2 Analisis Regresi Multivariat.....                                        | 31        |
| 3.2.1 Pengujian Distribusi Multivariat Normal.....                           | 32        |
| 3.2.1.1 Q-Q Plot Jarak Mahalanobis.....                                      | 32        |
| 3.2.1.2 Asumsi Normal Multivariat Variabel Respon.....                       | 34        |
| 3.2.2 Pengecekan VIF Multikolineritas.....                                   | 34        |
| 3.2.3 Seleksi Variabel.....                                                  | 35        |
| 3.2.4 Pengujian Signifikan Serentak secara Multivariat.....                  | 36        |
| 3.2.5 Uji Multivariat untuk Model Regresi Linier.....                        | 37        |
| 3.3 Analisis Korespondensi Berganda.....                                     | 41        |
| <b>DAFTAR PUSTAKA.....</b>                                                   | <b>46</b> |
| <b>LAMPIRAN.....</b>                                                         | <b>47</b> |

# BAB I PENDAHULUAN

## 1.1 Latar Belakang

Dalam era modern saat ini, persaingan bisnis semakin ketat dan terus berevolusi. Dalam meningkatkan daya saing suatu bisnis, diperlukan pemahaman yang mendalam terhadap karakteristik pelanggan yang dimilikinya. Pemahaman ini berguna untuk merancang strategi pemasaran yang efektif. Dalam penelitian ini akan dilakukan *Customer Personality Analysis*, yakni proses analisis yang bertujuan untuk menggali informasi mengenai karakteristik dari pelanggan ideal perusahaan secara mendalam.

Melalui *Customer Personality Analysis*, perusahaan dapat dengan lebih mudah memahami perilaku, kebutuhan, kebiasaan, dan preferensi pelanggan secara lebih spesifik. Analisis ini tidak hanya memungkinkan perusahaan untuk memodifikasi produk agar lebih sesuai dengan kebutuhan pelanggan, tetapi juga membantu dalam mengoptimalkan strategi pemasaran melalui segmentasi pasar agar lebih tepat sasaran. Sebagai contoh, dibandingkan dengan membuang biaya untuk memasarkan produk baru secara menyeluruh kepada seluruh pelanggan, perusahaan dapat mengidentifikasi segmen pelanggan yang paling potensial untuk produk tersebut, lalu mengupayakan pemasaran hanya ke segmen tersebut, sehingga biaya dan efektivitas promosi dapat dikelola dengan lebih efisien (Kotler & Keller, 2016).

Dalam melakukan analisis, penelitian ini menerapkan beberapa metode analisis statistik yang saling melengkapi, yaitu analisis klustering, analisis regresi multivariat, dan analisis korespondensi berganda. Dengan memanfaatkan pendekatan analisis klustering, penelitian ini mengelompokkan pelanggan ke dalam segmen-segmen yang memiliki pola konsumsi dan preferensi serupa. Selanjutnya, melalui analisis regresi multivariat, proyek ini menguji faktor-faktor yang memengaruhi pengeluaran pelanggan di berbagai kategori produk secara signifikan. Selain itu, analisis korespondensi berganda digunakan untuk mengeksplorasi hubungan antara variabel kategorik terhadap variabel dependen. Kombinasi ketiga metode ini diharapkan mampu memberikan wawasan yang bermanfaat mengenai struktur perilaku pelanggan, yang dapat digunakan sebagai dasar pengambilan keputusan perusahaan.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang dan situasi yang terjadi, kami merumuskan beberapa rumusan masalah sebagai berikut.

1. Bagaimana segmentasi pelanggan dapat dibentuk berdasarkan karakteristik demografis, perilaku pembelian, dan respons terhadap promosi menggunakan analisis klustering?
2. Faktor-faktor apa saja yang secara simultan memengaruhi jumlah pengeluaran pelanggan pada berbagai kategori produk berdasarkan analisis regresi multivariat?

3. Bagaimana hubungan antar variabel kategorik, seperti tingkat pendidikan, status pernikahan, dan penerimaan promosi, dapat diidentifikasi dan divisualisasikan melalui analisis korespondensi berganda?

### 1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diajukan, didapat tujuan dari penelitian yang kami lakukan sebagai berikut.

1. Mengidentifikasi segmentasi pelanggan berdasarkan karakteristik demografis, perilaku pembelian, dan respons terhadap promosi menggunakan metode analisis klustering.
2. Menganalisis pengaruh berbagai faktor seperti pendapatan, komposisi rumah tangga, serta perilaku belanja terhadap total pengeluaran pelanggan pada berbagai kategori produk menggunakan analisis regresi multivariat dan korespondensi berganda.

### 1.4 Informasi Dataset

Digunakan dataset berjudul “Customer Personality Analysis” yang bersumber dari <https://www.kaggle.com/datasets/imakash3011/customer-personality-analysis/data>. Dataset berjumlah 2.240 baris observasi dari pelanggan dan 29 kolom yang berisi variabel respon dan variabel prediktor. Berikut adalah detail variabel yang terdapat pada data “Customer Personality Analysis”.

| Kolom          | Tipe Data | Penjelasan                                                 |
|----------------|-----------|------------------------------------------------------------|
| ID             | Integer   | ID unik untuk setiap pelanggan                             |
| Year_Birth     | Integer   | Tahun kelahiran pelanggan                                  |
| Education      | Object    | Tingkat pendidikan pelanggan (Graduation, PhD, Basic, dsb) |
| Marital_Status | Object    | Status pernikahan pelanggan                                |
| Income         | Float     | Pendapatan tahunan rumah tangga                            |
| Kidhome        | Integer   | Jumlah anak kecil di rumah                                 |
| Teenhome       | Integer   | Jumlah remaja di rumah                                     |
| Dt_Customer    | Object    | Tanggal pertama kali bergabung sebagai pelanggan           |
| Recency        | Integer   | Hari sejak pembelian terakhir                              |

|                     |         |                                                                |
|---------------------|---------|----------------------------------------------------------------|
| MntWines            | Integer | Jumlah pembelanjaan untuk <i>wine</i> dalam 2 tahun terakhir   |
| MntFruits           | Integer | Jumlah pembelanjaan untuk buah dalam 2 tahun terakhir          |
| MntMeatProducts     | Integer | Jumlah pembelanjaan untuk daging dalam 2 tahun terakhir        |
| MntFishProducts     | Integer | Jumlah pembelanjaan untuk ikan dalam 2 tahun terakhir          |
| MntSweetProducts    | Integer | Jumlah pembelanjaan untuk manisan dalam 2 tahun terakhir       |
| MntGoldProds        | Integer | Jumlah pembelanjaan untuk produk emas dalam 2 tahun terakhir   |
| NumDealsPurchases   | Integer | Jumlah pembelian yang dilakukan dengan diskon                  |
| NumWebPurchases     | Integer | Jumlah pembelian yang dilakukan via website                    |
| NumCatalogPurchases | Integer | Jumlah pembelian yang dilakukan melalui katalog                |
| NumStorePurchases   | Integer | Jumlah pembelian yang dilakukan langsung di toko               |
| NumWebVisitsMonth   | Integer | Jumlah kunjungan ke website dalam 1 bulan terakhir             |
| AcceptedCmp1        | Integer | 1 jika pelanggan menerima penawaran promosi ke-1, 0 jika tidak |
| AcceptedCmp2        | Integer | 1 jika pelanggan menerima penawaran promosi ke-2, 0 jika tidak |
| AcceptedCmp3        | Integer | 1 jika pelanggan menerima penawaran promosi ke-3, 0 jika tidak |
| AcceptedCmp4        | Integer | 1 jika pelanggan menerima                                      |

|               |         |                                                                                      |
|---------------|---------|--------------------------------------------------------------------------------------|
|               |         | penawaran promosi ke-4, 0 jika tidak                                                 |
| AcceptedCmp5  | Integer | 1 Jika pelanggan menerima penawaran promosi ke-5, 0 jika tidak                       |
| Complain      | Integer | 1 Jika pelanggan pernah melakukan complain selama 2 tahun terakhir, dan 0 jika tidak |
| Z_CostContact | Integer | Biaya pemasaran tetap (seluruhnya 3 sehingga diabaikan)                              |
| Z_Revenue     | Integer | Pendapatan tetap (seluruhnya 11 sehingga diabaikan)                                  |
| Response      | Integer | 1 Jika pelanggan menerima penawaran terakhir, 0 jika tidak.                          |

## BAB 2 PREPROCESSING

### 2.1 Informasi Data

Berikut adalah informasi awal pada data.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2240 entries, 0 to 2239
Data columns (total 29 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ID                     2240 non-null  int64
1   Year_Birth             2240 non-null  int64
2   Education               2240 non-null  object
3   Marital_Status         2240 non-null  object
4   Income                 2216 non-null  float64
5   Kidhome                2240 non-null  int64
6   Teenhome               2240 non-null  int64
7   Dt_Customer            2240 non-null  object
8   Recency                2240 non-null  int64
9   MntWines               2240 non-null  int64
10  MntFruits              2240 non-null  int64
11  MntMeatProducts        2240 non-null  int64
12  MntFishProducts        2240 non-null  int64
13  MntSweetProducts       2240 non-null  int64
14  MntGoldProds           2240 non-null  int64
15  NumDealsPurchases      2240 non-null  int64
16  NumWebPurchases        2240 non-null  int64
17  NumCatalogPurchases    2240 non-null  int64
18  NumStorePurchases      2240 non-null  int64
19  NumWebVisitsMonth      2240 non-null  int64
20  AcceptedCmp3           2240 non-null  int64
21  AcceptedCmp4           2240 non-null  int64
22  AcceptedCmp5           2240 non-null  int64
23  AcceptedCmp1           2240 non-null  int64
24  AcceptedCmp2           2240 non-null  int64
25  Complain               2240 non-null  int64
26  Z_CostContact           2240 non-null  int64
27  Z_Revenue              2240 non-null  int64
28  Response               2240 non-null  int64

dtypes: float64(1), int64(25), object(3)
memory usage: 507.6+ KB
(
None,
  ID   Year_Birth  Education  Marital_Status  Income  Kidhome  Teenhome  \
0  5524      1957  Graduation      Single    58138.0      0      0
1  2174      1954  Graduation      Single    46344.0      1      1
2  4141      1965  Graduation      Together   71613.0      0      0
3  6182      1984  Graduation      Together   26646.0      1      0
4  5324      1981      PhD      Married    58293.0      1      0

  Dt_Customer  Recency  MntWines  ...  NumWebVisitsMonth  AcceptedCmp3  \
0  04-09-2012      58      635  ...              7              0
1  08-03-2014      38       11  ...              5              0
2  21-08-2013      26     426  ...              4              0
3  10-02-2014      26       11  ...              6              0
4  19-01-2014      94      173  ...              5              0

  AcceptedCmp4  AcceptedCmp5  AcceptedCmp1  AcceptedCmp2  Complain  \
0              0              0              0              0              0
1              0              0              0              0              0
2              0              0              0              0              0
3              0              0              0              0              0
4              0              0              0              0              0

  Z_CostContact  Z_Revenue  Response
0              3          11         1
1              3          11         0
2              3          11         0
3              3          11         0
4              3          11         0

[5 rows x 29 columns])
```

Data yang digunakan dalam analisis ini terdiri dari 2.240 entri dengan 29 kolom, di mana mayoritas variabel berjenis integer (25 kolom), satu kolom float64 untuk Income, dan tiga kolom bertipe object untuk Education, Marital\_Status, dan Dt\_Customer. Kolom Income memiliki 24 nilai yang hilang (non-null count 2.216), sementara kolom lainnya tidak memiliki nilai yang hilang (non-null count 2.240).

Kolom ID dan Year\_Birth mencatat informasi individu, sedangkan kolom Education, Marital\_Status, dan Dt\_Customer mencatat data kategorikal seperti tingkat pendidikan, status perkawinan, dan tanggal bergabung sebagai pelanggan. Beberapa kolom penting lainnya mencatat pembelian produk tertentu (misalnya MntWines, MntFruits, MntMeatProducts), aktivitas pembelian seperti NumWebPurchases, NumCatalogPurchases, serta respons kampanye yang diterima (AcceptedCmp1, AcceptedCmp2, dll.).

Terkait dengan kolom Response, yang berisi indikator apakah pelanggan menanggapi kampanye atau tidak, data menunjukkan bahwa sejumlah besar pelanggan tidak menanggapi kampanye (Response = 0). Selain itu, terdapat juga kolom Z\_CostContact dan Z\_Revenue yang



masing-masing menunjukkan biaya dan pendapatan terkait pelanggan, yang dapat digunakan untuk menganalisis kontribusi pelanggan terhadap bisnis.

## 2.2 Pengecekan Missing Value dan Statistika Deskriptif

```
(ID
Year_Birth
Education
Marital_Status
Income
Kidhome
Teenhome
Dt_Customer
Recency
MntWines
MntFruits
MntMeatProducts
MntFishProducts
MntSweetProducts
MntGoldProds
NumDealsPurchases
NumWebPurchases
NumCatalogPurchases
NumStorePurchases
NumWebVisitsMonth
AcceptedCmp3
AcceptedCmp4
AcceptedCmp5
AcceptedCmp1
AcceptedCmp2
Complain
Z_CostContact
Z_Revenue
Response
dtype: int64,
```

```
[8 rows x 26 columns],
ID int64
Year_Birth int64
Education object
Marital_Status object
Income float64
Kidhome int64
Teenhome int64
Dt_Customer object
Recency int64
MntWines int64
MntFruits int64
MntMeatProducts int64
MntFishProducts int64
MntSweetProducts int64
MntGoldProds int64
NumDealsPurchases int64
NumWebPurchases int64
NumCatalogPurchases int64
NumStorePurchases int64
NumWebVisitsMonth int64
AcceptedCmp3 int64
AcceptedCmp4 int64
AcceptedCmp5 int64
AcceptedCmp1 int64
AcceptedCmp2 int64
Complain int64
Z_CostContact int64
Z_Revenue int64
Response int64
dtype: object)
```

```
count 2240.000000 2240.000000 2216.000000 2240.000000 2240.000000 \
mean 5592.159821 1968.895804 52247.251954 0.444196 0.506250
std 1246.662198 11.984069 25173.076661 0.530398 0.544518
min 0.000000 1893.000000 1730.000000 0.000000 0.000000
25% 2828.250000 1959.000000 35303.000000 0.000000 0.000000
50% 5458.500000 1970.000000 51381.500000 0.000000 0.000000
75% 8627.750000 1977.000000 68521.000000 1.000000 1.000000
max 11191.000000 1996.000000 66666.000000 2.000000 2.000000

count 2240.000000 2240.000000 2240.000000 2240.000000 \
mean 49.109375 303.935714 26.302232 166.950000
std 28.962453 336.597393 39.773434 225.715373
min 0.000000 0.000000 0.000000 0.000000
25% 24.000000 23.750000 1.000000 16.000000
50% 49.000000 173.500000 8.000000 67.000000
75% 74.000000 504.250000 33.000000 232.000000
max 99.000000 1493.000000 159.000000 1725.000000

MntFishProducts ... NumWebVisitsMonth AcceptedCmp3 AcceptedCmp4 \
count 2240.000000 ... 2240.000000 2240.000000 2240.000000
mean 37.525446 ... 5.316518 0.872768 0.074554
std 54.628979 ... 2.426645 0.259813 0.262728
min 0.000000 ... 0.000000 0.000000 0.000000
25% 3.000000 ... 0.000000 0.000000 0.000000
50% 12.000000 ... 6.000000 0.000000 0.000000
75% 50.000000 ... 7.000000 0.000000 0.000000
max 259.000000 ... 20.000000 1.000000 1.000000

AcceptedCmp5 AcceptedCmp1 AcceptedCmp2 Complain Z_CostContact \
count 2240.000000 2240.000000 2240.000000 2240.000000 2240.0
mean 0.072768 0.064286 0.013393 0.009375 3.0
std 0.259813 0.245316 0.114976 0.096391 0.0
min 0.000000 0.000000 0.000000 0.000000 3.0
25% 0.000000 0.000000 0.000000 0.000000 3.0
50% 0.000000 0.000000 0.000000 0.000000 3.0
75% 0.000000 0.000000 0.000000 0.000000 3.0
max 1.000000 1.000000 1.000000 1.000000 3.0

Z_Revenue Response
count 2240.0 2240.000000
mean 11.0 0.149187
std 0.0 0.356274
min 11.0 0.000000
25% 11.0 0.000000
50% 11.0 0.000000
75% 11.0 0.000000
max 11.0 1.000000
```

Dataset ini berisi 2.240 entri dengan 29 kolom. Mayoritas kolom berisi data bertipe integer (25 kolom), dengan satu kolom bertipe float64 untuk Income, dan tiga kolom bertipe object untuk Education, Marital\_Status, dan Dt\_Customer. Data ini menunjukkan 24 nilai hilang di kolom Income, yang perlu diperhatikan saat melakukan analisis lebih lanjut. Semua kolom lainnya tidak memiliki nilai yang hilang.

Secara deskriptif, Income memiliki rata-rata 52.247 dengan rentang nilai yang cukup besar, mulai dari 1.730 hingga 666.666. Data ini menunjukkan adanya ketimpangan distribusi, karena beberapa pelanggan memiliki pendapatan yang sangat tinggi. Kidhome dan Teenhome mencatat rata-rata sekitar 0.44 dan 0.51, yang menunjukkan sebagian besar pelanggan tidak memiliki anak atau remaja di rumah. Variabel Recency memiliki rata-rata 49.11, yang menggambarkan waktu sejak pelanggan terakhir berinteraksi dengan perusahaan, dengan sebagian besar nilai berada di kisaran 24 hingga 74 bulan.

Untuk pembelian produk, kolom MntWines, MntFruits, dan MntMeatProducts menunjukkan variasi yang cukup besar. Rata-rata pembelian MntWines adalah 303.94, MntFruits 26.30, dan MntMeatProducts 166.95, dengan beberapa pelanggan melakukan pembelian sangat tinggi (misalnya MntWines mencapai 1493). Kolom AcceptedCmp1 hingga AcceptedCmp5

mengindikasikan bahwa sebagian besar pelanggan tidak menerima kampanye apapun, sedangkan kolom Response menunjukkan bahwa sekitar 15% pelanggan merespons kampanye.

Kolom Z\_CostContact dan Z\_Revenue memiliki nilai tetap 3, yang mengindikasikan biaya dan pendapatan yang seragam terkait dengan pelanggan dalam dataset ini.

Karena terdapat missing values pada Income, dilakukan imputasi dengan nilai mean dan dicek kembali missing values nya untuk memastikan tidak ada lagi missing values.

|                     |   |
|---------------------|---|
|                     | 0 |
| ID                  | 0 |
| Year_Birth          | 0 |
| Education           | 0 |
| Marital_Status      | 0 |
| Income              | 0 |
| Kidhome             | 0 |
| Teenhome            | 0 |
| Dt_Customer         | 0 |
| Recency             | 0 |
| MntWines            | 0 |
| MntFruits           | 0 |
| MntMeatProducts     | 0 |
| MntFishProducts     | 0 |
| MntSweetProducts    | 0 |
| MntGoldProds        | 0 |
| NumDealsPurchases   | 0 |
| NumWebPurchases     | 0 |
| NumCatalogPurchases | 0 |
| NumStorePurchases   | 0 |
| NumWebVisitsMonth   | 0 |
| AcceptedCmp3        | 0 |
| AcceptedCmp4        | 0 |
| AcceptedCmp5        | 0 |
| AcceptedCmp1        | 0 |
| AcceptedCmp2        | 0 |
| Complain            | 0 |
| Z_CostContact       | 0 |
| Z_Revenue           | 0 |
| Response            | 0 |

dtype: int64

### 3.3 Mendrop Kolom Yang Tida Memiliki Kontribusi

```
[ ] # Mendrop kolom yang tidak memiliki kontribusi
data=data.drop(columns=["Z_CostContact", "Z_Revenue"],axis=1)
data.head()
```

|   | ID   | Year_Birth | Education  | Marital_Status | Income  | Kidhome | Teenhome | Dt_Customer | Recency | Mntbines | ... | NumCatalogPurchases | NumStorePurchases | NumWebVisitsMonth | AcceptedCmp3 | AcceptedCmp4 | AcceptedCmp5 | AcceptedCmp6 |
|---|------|------------|------------|----------------|---------|---------|----------|-------------|---------|----------|-----|---------------------|-------------------|-------------------|--------------|--------------|--------------|--------------|
| 0 | 5524 | 1957       | Graduation | Single         | 58138.0 | 0       | 0        | 04-09-2012  | 58      | 635      | ... | 10                  | 4                 | 7                 | 0            | 0            | 0            | 0            |
| 1 | 2174 | 1954       | Graduation | Single         | 46344.0 | 1       | 1        | 08-03-2014  | 38      | 11       | ... | 1                   | 2                 | 5                 | 0            | 0            | 0            | 0            |
| 2 | 4141 | 1965       | Graduation | Together       | 71613.0 | 0       | 0        | 21-08-2013  | 26      | 426      | ... | 2                   | 10                | 4                 | 0            | 0            | 0            | 0            |
| 3 | 6182 | 1984       | Graduation | Together       | 26646.0 | 1       | 0        | 10-02-2014  | 26      | 11       | ... | 0                   | 4                 | 6                 | 0            | 0            | 0            | 0            |
| 4 | 5324 | 1981       | PhD        | Married        | 58293.0 | 1       | 0        | 19-01-2014  | 94      | 173      | ... | 3                   | 6                 | 5                 | 0            | 0            | 0            | 0            |

Dataset ini telah dibersihkan dengan menghapus kolom yang tidak relevan, dan sekarang lebih fokus pada informasi yang penting untuk analisis.

### 3.4 Menggabungkan Kategori Status Pernikahan

```
#mengecek kategori status pernikahan
data['Marital_Status'].value_counts()
```

| Marital_Status | count |
|----------------|-------|
| Married        | 884   |
| Together       | 580   |
| Single         | 480   |
| Divorced       | 232   |
| Widow          | 77    |
| Alone          | 3     |
| Absurd         | 2     |
| YOLO           | 2     |

dtype: int64

Menggabung 'Married', 'Together' menjadi "relationship" dan menggabung 'Divorced', 'Widow', 'Alone', 'YOLO', 'Absurd' menjadi "Single"

```
[ ] data['Marital_Status'] = data['Marital_Status'].replace(['Married', 'Together'], 'relationship')
data['Marital_Status'] = data['Marital_Status'].replace(['Divorced', 'Widow', 'Alone', 'YOLO', 'Absurd'], 'Single')

[ ] data['Marital_Status'].value_counts()
```

| Marital_Status | count |
|----------------|-------|
| relationship   | 1444  |
| Single         | 796   |

dtype: int64

Berdasarkan hasil analisis pada kolom Marital\_Status, terdapat beberapa kategori yang mencatat jumlah berbeda, yaitu Married (884 entri), Together (580 entri), Single (480 entri), Divorced (232 entri), Widow (77 entri), Alone (3 entri), Absurd (2 entri), dan YOLO (2 entri). Untuk menyederhanakan data, kategori Married dan Together digabung menjadi satu kategori relationship, sementara kategori Divorced, Widow, Alone, YOLO, dan Absurd digabung menjadi kategori Single. Setelah perubahan ini, kolom Marital\_Status hanya memiliki dua kategori utama,

yaitu relationship (1444 entri) dan Single (796 entri). Kesimpulannya, proses pembersihan data ini berhasil menyederhanakan variabel Marital\_Status, membuatnya lebih mudah untuk dianalisis dan digunakan dalam model selanjutnya.

### 3.5 Mengurangi Dimensi dan Kompleksitas Model.

```
# Menggabungkan beberapa dataframe menjadi satu kolom untuk mereduksi dimensi
data['Kids'] = data['Kidhome'] + data['Teenhome']
data['Expenses'] = data['MntWines'] + data['MntFruits'] + data['MntMeatProducts'] + data['MntFishProducts'] + data['MntSweetProducts'] + data['MntGoldProds']
data['TotalAcceptedCmp'] = data['AcceptedCmp1'] + data['AcceptedCmp2'] + data['AcceptedCmp3'] + data['AcceptedCmp4'] + data['AcceptedCmp5'] + data['Response']
data['NumTotalPurchases'] = data['NumWebPurchases'] + data['NumCatalogPurchases'] + data['NumStorePurchases'] + data['NumDealsPurchases']

# Menghapus beberapa kolom (variabel) dalam dataset untuk mengurangi dimensi dan kompleksitas model.
col_del = ["AcceptedCmp1", "AcceptedCmp2", "AcceptedCmp3", "AcceptedCmp4", "AcceptedCmp5", "Response", "NumWebVisitsMonth", "NumWebPurchases", "NumCatalogPurchases", "NumStorePurchases", "NumDealsPurchases", "Kidhome", "Teenhome", "MntWines", "MntFruit"]
data = data.drop(columns=col_del, axis=1)
data.head()
```

|   | ID   | Year_Birth | Education  | Marital_Status | Income  | Dt_Customer | Recency | Complain | Kids | Expenses | TotalAcceptedCmp | NumTotalPurchases |
|---|------|------------|------------|----------------|---------|-------------|---------|----------|------|----------|------------------|-------------------|
| 0 | 5524 | 1957       | Graduation | Single         | 58138.0 | 04-08-2012  | 58      | 0        | 0    | 1617     | 1                | 25                |
| 1 | 2174 | 1954       | Graduation | Single         | 46344.0 | 08-03-2014  | 38      | 0        | 2    | 27       | 0                | 6                 |
| 2 | 4141 | 1955       | Graduation | relationship   | 71613.0 | 21-08-2013  | 26      | 0        | 0    | 778      | 0                | 21                |
| 3 | 6182 | 1984       | Graduation | relationship   | 20648.0 | 10-02-2014  | 26      | 0        | 1    | 53       | 0                | 8                 |
| 4 | 5324 | 1981       | PhD        | relationship   | 58293.0 | 19-01-2014  | 94      | 0        | 1    | 422      | 0                | 19                |

Langkah berikutnya: [Buat kode dengan data](#) [Lihat plot yang direkomendasikan](#) [New interactive sheet](#)

```
[ ] # Menambah kolom "age" ke dataframe
data['Age'] = 2025 - data['Year_Birth']
```

Beberapa langkah pemrosesan data telah dilakukan untuk meningkatkan kualitas dataset. Pertama, beberapa kolom digabungkan untuk mengurangi dimensi dan kompleksitas model. Kolom Kidhome dan Teenhome digabungkan menjadi satu kolom Kids, sementara kolom Expenses dihitung sebagai jumlah pengeluaran pelanggan untuk beberapa kategori produk seperti MntWines, MntFruits, dan MntMeatProducts.

Selain itu, kolom NumTotalPurchases dihitung dengan menjumlahkan NumWebPurchases, NumCatalogPurchases, dan NumStorePurchases untuk mendapatkan total pembelian. Kemudian, beberapa kolom yang dianggap tidak memberikan kontribusi signifikan terhadap analisis dihapus, seperti AcceptedCmp1, AcceptedCmp2, AcceptedCmp3, AcceptedCmp4, AcceptedCmp5, Response, dan beberapa kolom terkait pembelian dan frekuensi pengunjung. Selanjutnya, kolom baru Age ditambahkan ke dataset dengan rumus  $\text{Age} = 2025 - \text{Year\_Birth}$ , yang menghitung usia pelanggan berdasarkan tahun kelahiran mereka.

Dataset yang dimodifikasi ini menunjukkan kolom-kolom seperti Year\_Birth, Education, Marital\_Status, Income, Dt\_Customer, Recency, Kids, Expenses, TotalAcceptedCmp, dan NumTotalPurchases. Secara keseluruhan, langkah-langkah ini berhasil menyederhanakan dataset dan membuatnya lebih siap untuk pemodelan dan analisis lebih lanjut, dengan penambahan kolom Age yang memberikan informasi penting tentang usia pelanggan.

### 3.6 Menggabungkan Kategori Pendidikan

```
data['Education'].value_counts()

count
Education
Graduation    1127
PhD            488
Master         370
2n Cycle       203
Basic          54
dtype: int64

[ ] # Mengubah kategori yang ada menjadi hanya dua kelompok: UG (Undergraduate) dan PG (Postgraduate).

data['Education'] = data['Education'].replace(['PhD', '2n Cycle', 'Graduation', 'Master'], 'PG')
data['Education'] = data['Education'].replace(['Basic'], 'UG')
```

Kolom Education menunjukkan distribusi tingkat pendidikan pelanggan dalam dataset. Terdapat lima kategori pendidikan: Graduation (1.127 entri), PhD (488 entri), Master (370 entri), 2n Cycle (203 entri), dan Basic (54 entri). Setelah itu, dilakukan pemrosesan untuk menyederhanakan kategori pendidikan ini menjadi dua kelompok utama, yaitu UG (Undergraduate) untuk Graduation, 2n Cycle, dan Basic, serta PG (Postgraduate) untuk PhD, Master, dan Graduation. Dengan perubahan ini, kategori pendidikan kini terdiri dari dua kelompok utama: UG dan PG, yang lebih memudahkan dalam analisis dan pemodelan lebih lanjut.

### 3.7 Format Datetime

```
[ ] # menghitung jumlah hari seorang pelanggan terlibat atau berinteraksi dengan perusahaan sejak tanggal tertentu.

# mengubah kolom Dt_customer yang berisi tanggal menjadi format timestamp yang benar
data['Dt_Customer'] = pd.to_datetime(data.Dt_Customer, format='%d-%m-%Y')
data['first_day'] = '01-01-2015'
data['first_day'] = pd.to_datetime(data.first_day)
data['day_engaged'] = (data['first_day'] - data['Dt_Customer']).dt.days
```

Langkah pertama adalah menghitung jumlah hari yang telah berlalu sejak pelanggan pertama kali berinteraksi atau bergabung dengan perusahaan. Proses ini dimulai dengan mengubah kolom Dt\_Customer, yang berisi tanggal, menjadi format timestamp yang sesuai menggunakan fungsi pd.to\_datetime(). Tanggal dalam kolom Dt\_Customer yang awalnya dalam format '%d-%m-%Y' diubah menjadi format datetime yang dapat diproses lebih lanjut.

Selanjutnya, kolom first\_day ditambahkan dengan menetapkan tanggal 01-01-2015 sebagai acuan untuk menghitung jumlah hari. Kolom first\_day kemudian diubah menjadi format timestamp dengan fungsi pd.to\_datetime(). Setelah itu, kolom baru day\_engaged dihitung dengan mengurangi Dt\_Customer dari first\_day, menghasilkan jumlah hari yang telah berlalu sejak pelanggan pertama kali berinteraksi dengan perusahaan.


### 3.8 Mendrop Kolom Yang Tidak Dibutuhkan

```
[ ] #Mendrop kolom yang tidak dibutuhkan
data=data.drop(columns=["ID", "Dt_Customer", "first_day", "Year_Birth", "Dt_Customer", "Recency", "Complain"],axis=1)
data.head()
```


|   | Education | Marital_Status | Income  | Kids | Expenses | TotalAcceptedCmp | NumTotalPurchases | Age | day_engaged |
|---|-----------|----------------|---------|------|----------|------------------|-------------------|-----|-------------|
| 0 | PG        | Single         | 58138.0 | 0    | 1617     | 1                | 25                | 68  | 849         |
| 1 | PG        | Single         | 46344.0 | 2    | 27       | 0                | 6                 | 71  | 299         |
| 2 | PG        | relationship   | 71613.0 | 0    | 776      | 0                | 21                | 60  | 498         |
| 3 | PG        | relationship   | 26646.0 | 1    | 53       | 0                | 8                 | 41  | 325         |
| 4 | PG        | relationship   | 58293.0 | 1    | 422      | 0                | 19                | 44  | 347         |

Dilakukan langkah pembersihan data dengan menghapus kolom yang tidak diperlukan. Kolom-kolom seperti ID, Dt\_Customer, first\_day, Year\_Birth, Recency, dan Complain dihapus karena dianggap tidak relevan atau tidak memiliki kontribusi signifikan terhadap analisis yang dilakukan.

### 3.9 Outlier



Outlier yang terlihat di berbagai kolom seperti Income, Expenses, NumTotalPurchases, dan Age mungkin menunjukkan data yang perlu dianalisis lebih lanjut. Meskipun sebagian besar data terdistribusi dalam kisaran yang lebih sempit, outlier ini bisa mengandung informasi yang berharga terkait pelanggan tertentu yang memiliki perilaku atau karakteristik yang berbeda. Oleh karena itu, meskipun outlier sering dianggap sebagai "kesalahan" atau data yang tidak normal, dalam beberapa kasus mereka dapat menyediakan wawasan berharga, dan penggunaan teknik Winsorization (seperti IQR Winsorization) bisa dilakukan untuk mengatasi masalah ini tanpa menghilangkan informasi penting.



Setelah diterapkannya imputasi menggunakan IQR Winsorization pada kolom Income, distribusi data menjadi lebih terfokus, mengurangi pengaruh outliers yang bisa memengaruhi analisis selanjutnya. Data pendapatan kini lebih konsisten, dengan sebagian besar pelanggan memiliki pendapatan yang berada dalam kisaran normal. Hal ini memudahkan untuk melakukan analisis lebih lanjut atau membangun model prediktif tanpa terganggu oleh nilai ekstrim yang bisa mendistorsi hasil.

### 3.10 Statistika Deskriptif dari Data Yang Sudah Dibersihkan


|       | Income        | Kids        | Expenses    | TotalAcceptedCmp | NumTotalPurchases | Age         | day_engaged |
|-------|---------------|-------------|-------------|------------------|-------------------|-------------|-------------|
| count | 2240.000000   | 2240.000000 | 2240.000000 | 2240.000000      | 2240.000000       | 2240.000000 | 2240.000000 |
| mean  | 51875.150461  | 0.950446    | 605.798214  | 0.446875         | 14.862054         | 56.194196   | 539.582143  |
| std   | 20936.079938  | 0.751803    | 602.249288  | 0.890543         | 7.677173          | 11.984069   | 202.122512  |
| min   | 1730.000000   | 0.000000    | 5.000000    | 0.000000         | 0.000000          | 29.000000   | 186.000000  |
| 25%   | 35538.750000  | 0.000000    | 68.750000   | 0.000000         | 8.000000          | 48.000000   | 366.750000  |
| 50%   | 51741.500000  | 1.000000    | 396.000000  | 0.000000         | 15.000000         | 55.000000   | 541.500000  |
| 75%   | 68289.750000  | 1.000000    | 1045.500000 | 1.000000         | 21.000000         | 66.000000   | 715.000000  |
| max   | 117416.250000 | 3.000000    | 2525.000000 | 5.000000         | 44.000000         | 132.000000  | 885.000000  |

Berdasarkan statistik deskriptif yang ditampilkan, variabel-variabel dalam dataset menunjukkan berbagai karakteristik penting. Rata-rata Income adalah 51.878, dengan standar deviasi yang besar (20.938), menunjukkan variasi pendapatan yang signifikan di antara pelanggan. Pendapatan minimum adalah 1.730, sementara pendapatan maksimum mencapai 117.416, menunjukkan adanya beberapa pelanggan dengan pendapatan jauh lebih tinggi. Rata-rata jumlah


Kids adalah 0.95, yang berarti sebagian besar pelanggan tidak memiliki anak atau hanya memiliki satu anak. Untuk pengeluaran (Expenses), rata-ratanya adalah 605.79, dengan standar deviasi 602.25, menunjukkan adanya variasi yang besar dalam pengeluaran pelanggan, dengan nilai maksimum mencapai 2.525. Rata-rata jumlah kampanye yang diterima oleh pelanggan (TotalAcceptedCmp) adalah 0.44, dengan sebagian besar pelanggan hanya menerima sedikit kampanye. Rata-rata jumlah total pembelian (NumTotalPurchases) adalah 14.88, dengan pelanggan melakukan antara 0 hingga 44 pembelian. Rata-rata usia pelanggan (Age) adalah 58.19, dengan rentang usia yang sangat bervariasi, antara 29 hingga 132 tahun. Terakhir, rata-rata jumlah hari terlibat (day\_engaged) adalah 202.12, dengan sebagian besar pelanggan berinteraksi dengan perusahaan dalam jangka waktu yang relatif panjang, antara 186 hingga 885 hari.


Secara keseluruhan, dataset ini mencakup informasi yang sangat beragam tentang pelanggan, dengan variasi yang signifikan dalam variabel seperti Income, Expenses, dan Age. Ini menunjukkan bahwa pelanggan dalam dataset ini memiliki karakteristik yang bervariasi. Beberapa variabel menunjukkan distribusi normal, sementara yang lain menunjukkan adanya outliers, yang dapat memberikan wawasan tambahan jika dianalisis lebih lanjut. Variabel-variabel ini penting untuk dianalisis lebih lanjut atau dimasukkan dalam model prediktif untuk memperoleh pemahaman yang lebih baik tentang perilaku pelanggan.

### 3.11 Plot Distribusi, Pairplot dan Heatmap Korelasi









Distribusi dan korelasi antar variabel dalam dataset menunjukkan beberapa pola yang menarik. Distribusi Income cenderung agak normal dengan sedikit skewness ke kanan, yang mengindikasikan bahwa sebagian besar pelanggan memiliki pendapatan lebih rendah, namun ada beberapa outliers dengan pendapatan sangat tinggi. Kids menunjukkan distribusi yang lebih diskrit, di mana sebagian besar pelanggan memiliki 0 atau 1 anak, dengan sedikit yang memiliki 2 atau 3 anak. Distribusi Expenses cenderung miring ke kanan, menunjukkan banyak pengeluaran yang lebih rendah dan beberapa pelanggan dengan pengeluaran sangat tinggi. TotalAcceptedCmp terpusat pada 0 dan 1, yang berarti sebagian besar pelanggan hanya menerima sedikit atau tidak ada kampanye, sementara NumTotalPurchases menunjukkan distribusi yang lebih seimbang meskipun terdapat beberapa nilai ekstrim. Age memiliki distribusi normal dengan sebagian besar pelanggan berusia antara 40 hingga 80 tahun, dan day\_engaged menunjukkan distribusi yang lebih datar dengan sebagian besar pelanggan berinteraksi dalam rentang waktu yang lebih panjang, sekitar 200 hingga 800 hari.

Dalam hal korelasi, Income memiliki korelasi positif yang kuat dengan Expenses (0.8), menunjukkan bahwa pelanggan dengan pendapatan lebih tinggi cenderung memiliki pengeluaran yang lebih tinggi. Income juga berkorelasi positif moderat dengan NumTotalPurchases (0.75), yang berarti pelanggan dengan pendapatan lebih tinggi cenderung melakukan lebih banyak pembelian. NumTotalPurchases dan Expenses juga menunjukkan korelasi yang kuat (0.75), yang mengindikasikan bahwa pelanggan yang lebih banyak membeli cenderung menghabiskan lebih banyak uang. Namun, day\_engaged menunjukkan korelasi yang rendah dengan variabel lainnya, yang menunjukkan bahwa jumlah hari yang terlibat dengan perusahaan tidak berkorelasi langsung dengan faktor-faktor seperti Income atau Expenses.

Secara keseluruhan, data menunjukkan pola yang konsisten, dengan korelasi signifikan antara pendapatan dan pengeluaran, serta jumlah pembelian. Namun, `day_engaged` menunjukkan sedikit hubungan dengan variabel lain, yang bisa berarti bahwa keterlibatan pelanggan tidak terlalu dipengaruhi oleh faktor-faktor seperti pendapatan atau jumlah pembelian. Outlier pada `Income` dan `Expenses` juga penting untuk dianalisis lebih lanjut karena mereka bisa mengindikasikan pola pembelian atau perilaku pelanggan yang berbeda. Sebagai langkah selanjutnya, analisis lebih mendalam terhadap kelompok pelanggan dengan outlier ini bisa memberikan wawasan tambahan mengenai perilaku konsumsi mereka.

## BAB 3 ANALISIS

### 3.1 Analisis Klastering

Analisis klastering dilakukan untuk mengelompokkan data pelanggan berdasarkan kemiripan karakteristik mereka, dengan tujuan mengidentifikasi segmen-segmen yang memiliki pola perilaku yang seragam. Dalam penelitian ini, metode yang digunakan adalah klastering hierarki dan non-hierarki (K-Means), masing-masing memberikan sudut pandang yang saling melengkapi.

#### 3.1.1 Klastering Hieararki

Untuk melakukan klastering hierarki, pertama dilakukan standarisasi data ke bentuk normal dengan scaler karena data tidak berdistribusi normal multivariat berdasarkan uji pada **bagian 3.2.1**. Hal ini dilakukan karena ingin dibentuk jarak euclidean sehingga data lebih seragam dan dapat terinterpretasikan dengan baik.

```
1 # Ambil kolom numerik untuk clustering
2 kolom_clustering = ["Income", "Kids", "Expenses", "TotalAcceptedCmp",
3                     "NumTotalPurchases", "Age", "day_engaged"]
4 df_numeric = df[kolom_clustering]
5 scaler = StandardScaler()
6 df_scaled = scaler.fit_transform(df_numeric)
7 data_scaled = pd.DataFrame(df_scaled, columns=kolom_clustering)
8 data_scaled.head()
```

|   | Income    | Kids      | Expenses  | TotalAcceptedCmp | NumTotalPurchases | Age       | day_engaged |
|---|-----------|-----------|-----------|------------------|-------------------|-----------|-------------|
| 0 | 0.235327  | -1.264505 | 1.679417  | 0.621248         | 1.320826          | 0.985345  | 1.531185    |
| 1 | -0.235826 | 1.396361  | -0.961275 | -0.501912        | -1.154596         | 1.235733  | -1.190545   |
| 2 | 0.773633  | -1.264505 | 0.282673  | -0.501912        | 0.799685          | 0.317643  | -0.205773   |
| 3 | -1.022732 | 0.065928  | -0.918094 | -0.501912        | -0.894025         | -1.268149 | -1.061881   |
| 4 | 0.241519  | 0.065928  | -0.305254 | -0.501912        | 0.539114          | -1.017761 | -0.953012   |

Selanjutnya, dilakukan transformasi variabel ke bentuk jarak euclidean:

$$d(A, B) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$

Transformasi ke jarak Euclidean dilakukan agar setiap observasi direpresentasikan dalam bentuk matriks jarak numerik yang seragam, sehingga klastering bisa mengukur kemiripan antar objek secara matematis. Euclidean distance adalah metode paling umum karena merepresentasikan jarak geometris langsung dalam ruang multidimensi terutama data yang sudah distandarisasi ke bentuk normal. Tanpa transformasi ini, metode linkage seperti Ward, average, atau complete tidak bisa menentukan gabungan antar klaster secara konsisten.

```

1 # Hitung jarak Euclidean antar observasi
2 euclidean_dist = pdist(df_scaled, metric='euclidean')
3
4 # Ubah jadi matriks segiempat
5 dist_matrix = squareform(euclidean_dist)
6 print(dist_matrix)



```




```

[[0.          5.3976994  2.69009194 ... 3.36678409 3.35417524 4.03914952]
 [5.3976994  0.          3.90877236 ... 4.53624533 3.06958682 2.85592814]
 [2.69009194 3.90877236 0.          ... 2.15740486 1.73766615 3.84738078]
 ...
 [3.36678409 4.53624533 2.15740486 ... 0.          2.88684584 4.66525017]
 [3.35417524 3.06958682 1.73766615 ... 2.88684584 0.          3.53432157]
 [4.03914952 2.85592814 3.84738078 ... 4.66525017 3.53432157 0.          ]]

```

Selanjutnya, berikut adalah plot dari metode clustering single linkage, complete linkage, average linkage, centroid linkage, dan ward linkage:





Berikut adalah nilai Cophenetic Correlation yang digunakan untuk mengukur seberapa baik hasil dendrogram mencerminkan jarak asli antar data dalam klastering hierarki dari masing-masing linkage, serta jumlah anggota masing-masing cluster untuk setiap linkage.

➡ Cophenetic Correlation (Single Linkage): 0.6053513006186122

➡ Cluster\_single

|   |      |
|---|------|
| 1 | 4    |
| 2 | 2234 |
| 3 | 1    |
| 4 | 1    |

Name: count, dtype: int64

Cophenetic Correlation (Complete Linkage): 0.5875261314772103

Cluster\_Complete

|   |      |
|---|------|
| 1 | 446  |
| 2 | 3    |
| 3 | 1790 |
| 4 | 1    |

Name: count, dtype: int64

➡ Cophenetic Correlation (Average Linkage): 0.7709526503627969

➡ Cluster\_Average

|   |      |
|---|------|
| 1 | 3    |
| 2 | 3    |
| 3 | 2233 |
| 4 | 1    |

Name: count, dtype: int64

➡ Cophenetic Correlation (Centroid Linkage): 0.7653103317208104

➡ Cluster\_Centroid

|   |      |
|---|------|
| 1 | 3    |
| 2 | 3    |
| 3 | 2233 |
| 4 | 1    |

Name: count, dtype: int64

➡ Cophenetic Correlation (Ward Linkage): 0.4622690345104416

➡ Cluster\_Ward

|   |     |
|---|-----|
| 1 | 441 |
| 2 | 835 |
| 3 | 74  |
| 4 | 890 |


Name: count, dtype: int64

➡ Cophenetic Correlation Summary

|   | method   | correlation |
|---|----------|-------------|
| 0 | complete | 0.587526    |
| 1 | single   | 0.605351    |
| 2 | average  | 0.770953    |
| 3 | centroid | 0.765310    |
| 4 | ward     | 0.462269    |

Berdasarkan dendogram, cophenetic correlation, dan jumlah data per cluster ditentukan jenis linkage terbaik, yakni Ward Linkage sebagai metode klastering hierarchy yang dipilih. Berdasarkan dendogram, struktur klaster lebih seimbang dibandingkan linkage lainnya serta klaster tersusun dengan rapih dan seimbang. Selain itu, terdapat sangat sedikit distorsi atau lonjakan ekstrem yang mendadak pada garis. Dengan demikian, prinsip Ward berfungsi dengan baik dalam model clustering, yakni meminimalkan variansi klaster. Hal ini didukung oleh jumlah data per cluster yang paling seimbang serta korelasi ward yang paling baik pada cophenetic correlation.

Selanjutnya, untuk menentukan jumlah cluster pada metode ward linkage, digunakan metode K-means dengan mengevaluasi elbow method, silhouette score, calinski-harabasz index, dan davies bouldin index.




Berdasarkan hasil evaluasi menggunakan empat metrik utama, jumlah klaster terbaik ditentukan sebanyak empat klaster ( $k = 4$ ). Metode elbow menunjukkan adanya lekukan yang jelas pada  $k = 4$ , menandakan titik optimal sebelum penurunan inertia menjadi lambat. Silhouette score masih cukup tinggi di  $k = 4$  dan menunjukkan pemisahan klaster yang baik tanpa terlalu banyak overlap. Calinski-Harabasz index juga masih relatif tinggi di  $k = 4$ , menunjukkan kualitas pemisahan yang efisien antar klaster. Meskipun nilai Davies-Bouldin paling rendah terjadi di  $k = 9$ , nilai di  $k = 4$  tetap kompetitif dan didukung



oleh ketiga metrik lainnya, menjadikan  $k = 4$  sebagai pilihan paling stabil dan seimbang secara keseluruhan. Dengan demikian, pembagian jumlah data per cluster pada metode ward adalah sebagai berikut.


| Cluster_Average           |     |
|---------------------------|-----|
| 1                         | 441 |
| 2                         | 835 |
| 3                         | 74  |
| 4                         | 890 |
| Name: count, dtype: int64 |     |

Dengan demikian, Ward Linkage Clustering dapat divisualisasikan dengan Principal Component Analysis sebagai berikut.




### 3.1.2 Klastering Non Hirarki

Analisis klastering non-hierarki dalam penelitian ini dilakukan menggunakan metode K-Means untuk mengelompokkan pelanggan berdasarkan kemiripan karakteristik numerik mereka. Metode ini bekerja dengan cara menginisialisasi sejumlah pusat klaster (centroid), lalu secara iteratif mengelompokkan data ke klaster terdekat berdasarkan jarak Euclidean hingga mencapai konvergensi. Berdasarkan evaluasi berbagai metrik seperti elbow method, silhouette score, Calinski-Harabasz index, dan Davies-Bouldin index, jumlah klaster optimal ditentukan sebanyak empat klaster. Hasil klastering divisualisasikan menggunakan reduksi dimensi PCA, yang memperlihatkan pemisahan yang cukup baik antar klaster dan mengindikasikan bahwa K-Means berhasil menangkap pola segmentasi pelanggan secara efektif dalam data.



### 3.1.3 Klastering Variabel

Klastering variabel dilakukan untuk mengelompokkan variabel-variabel yang memiliki pola distribusi atau hubungan yang serupa, sehingga dapat mempermudah interpretasi serta membantu dalam reduksi dimensi data. Dalam analisis ini, pendekatan yang digunakan adalah metode hierarki dengan Ward linkage, dengan dasar jarak berupa dissimilarity matrix  $1 - r^2$ , yang mencerminkan kekuatan hubungan antar variabel. Hasil dendrogram menunjukkan pembentukan beberapa klaster variabel yang merepresentasikan dimensi perilaku berbeda, seperti ekonomi, demografis, dan keterlibatan pelanggan. Klastering ini memberikan wawasan tentang struktur internal antar variabel dan memungkinkan analisis lebih fokus dengan cara mengelompokkan fitur-fitur yang memiliki fungsi mirip dalam satu grup representatif. Berikut adalah visualisasi dendrogram dari clustering variabel.




Berdasarkan kedua dendrogram yang menggunakan metode *Ward Linkage*, grafik pertama menggunakan jarak Euclidean biasa, sedangkan grafik kedua mengukur dissimilarity berdasarkan nilai  $1 - r^2$ . Keduanya menunjukkan pola pengelompokan variabel yang cukup konsisten. Variabel Income, Expenses, dan NumTotalPurchases cenderung membentuk satu kluster yang sama, menandakan adanya hubungan erat antar ketiganya. Di sisi lain, variabel Age, Kids, dan day\_engaged juga berkumpul dalam kluster tersendiri. Variabel TotalAcceptedCmp terlihat paling terpisah dalam kedua grafik, menunjukkan bahwa ia memiliki korelasi yang paling lemah dengan

variabel lainnya. Simpulan ini berguna untuk membantu proses seleksi variabel atau penyederhanaan model analisis lanjutan.

Selanjutnya, dapat dilihat bahwa partisi variabel yang dilakukan sangatlah baik, bahkan untuk bootstrap hingga 100. Hal ini mengindikasikan kestabilan klastering yang sudah dilakukan.

```
18 # Hitung stabilitas partisi antar variabel (berbasis Ward linkage)
19 X_vars = df[cols].values
20 stability_scores = bootstrap_stability(X_vars, method='ward', n_iter=100)
21 stability_scores
```

```
[np.float64(0.9999731359367007),
 np.float64(0.9999731267420863),
 np.float64(0.9999716198635955),
 np.float64(0.9999750848150406),
 np.float64(0.9999763215127757),
 np.float64(0.9999718903881335),
 np.float64(0.999969317433061),
 np.float64(0.999974412536081),
 np.float64(0.9999743325938202),
 np.float64(0.999971621719186),
 np.float64(0.9999737750257145),
 np.float64(0.9999726160419973),
 np.float64(0.9999702759826438),
 np.float64(0.9999723096382617),
 np.float64(0.9999713912454611),
 np.float64(0.9999727233804515),
 np.float64(0.9999776505722854),
 np.float64(0.9999816016490249),
 np.float64(0.9999688358258844),
 np.float64(0.9999767812798529),
 np.float64(0.9999715190328445),
 np.float64(0.9999756321850348),
 np.float64(0.9999714783564255),
 np.float64(0.9999691909196312),
 np.float64(0.9999764393321388),
 np.float64(0.9999752770518499),
 np.float64(0.9999687588231693),
 np.float64(0.9999716668596139),
 np.float64(0.999976768186045),
 np.float64(0.9999710888342446),
 np.float64(0.99997170470671)]
```




Maka, didapatkan jumlah clustering untuk masing-masing variabel yang optimal sebagai berikut.

Hasil Clustering Variabel (simulasi kmeansvar\$cluster):

|   | Variable          | Cluster |
|---|-------------------|---------|
| 0 | Income            | 0       |
| 1 | Expenses          | 0       |
| 2 | NumTotalPurchases | 0       |
| 3 | day_engaged       | 1       |
| 4 | TotalAcceptedCmp  | 2       |
| 5 | Kids              | 2       |
| 6 | Age               | 3       |

Didapatkan pula dendrogram akhir yang terbaik untuk tiap variabel sebagai berikut.



### 3.2 Analisis Regresi Multivariat

Analisis multivariat adalah suatu pendekatan dalam statistika yang digunakan untuk menganalisis data yang melibatkan lebih dari satu variabel yang saling berkorelasi. Berbeda dengan analisis univariat yang hanya mengkaji satu variabel saja, analisis multivariat bertujuan untuk memahami hubungan antara berbagai variabel sekaligus dalam satu set data. Dalam konteks ini, data yang digunakan terdiri dari sejumlah pengamatan yang mencakup banyak variabel, yang dapat berhubungan satu sama lain.

Sebagai contoh, jika ada  $n$  pengamatan yang dilakukan pada  $p$  variabel, data tersebut dapat diorganisir dalam bentuk sebuah matriks yang memiliki  $n$  baris (untuk masing-masing pengamatan) dan  $p$  kolom (untuk setiap variabel). Matriks ini biasanya dilambangkan dengan simbol  $Y$ , yang berfungsi sebagai representasi dari data multivariat yang dianalisis. Dengan demikian, analisis multivariat memungkinkan untuk mengeksplorasi dan memahami lebih dalam mengenai pola-pola yang ada dalam data yang memiliki banyak dimensi, serta bagaimana variabel-variabel tersebut saling berinteraksi (Morrison, 2005).

Model Regresi Multivariat adalah model regresi yang melibatkan lebih dari satu variabel respon yang saling berkorelasi, dan satu atau lebih variabel prediktor (Johnson & Wichern, 2007; Rencher, 2002). Misalnya, jika terdapat sejumlah variabel respon, yaitu  $y_1, y_2, \dots, y_p$  dan  $q$  variabel prediktor  $x_1, x_2, \dots, x_q$ , maka jumlah observasi yang dilakukan sebanyak  $n$  dapat dinyatakan dalam bentuk vektor berikut:

$$Y = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1p} \\ y_{21} & y_{22} & \cdots & y_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{np} \end{pmatrix} = \begin{pmatrix} y'_1 \\ y'_2 \\ \vdots \\ y'_n \end{pmatrix}$$

Sementara itu, nilai dari  $x_1, x_2, \dots, x_q$  dapat dinyatakan dalam matriks  $X$  sebagai berikut:

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

**Model Regresi Multivariat** dapat dituliskan dalam bentuk persamaan:

$$Y = XB + \Xi$$

di mana:

- $Y_{n \times p}$  adalah matriks data respon dengan  $n$  baris dan  $p$  kolom.
- $X_{n \times (q+1)}$  adalah matriks data prediktor, dengan  $n$  baris dan  $q+1$  kolom.
- $B_{(q+1) \times p}$  adalah matriks koefisien regresi.


**Asumsi yang digunakan dalam model ini adalah:**


1.  $E(Y) = X\beta$  atau  $E(\Xi) = 0$
2.  $Cov(y_i) = \sigma^2$  untuk setiap  $i=1,2,\dots,n$ , di mana  $y_i$  adalah baris ke- $i$  dari  $Y$ .
3.  $Cov(y_i, y_j) = 0$  untuk setiap  $i \neq j$

Dengan demikian, model regresi multivariat ini melibatkan dua matriks, yaitu matriks prediktor  $X$  dan matriks koefisien  $B$ , yang bersama-sama membentuk model untuk memprediksi variabel respon  $Y$  berdasarkan variabel prediktor.

### 3.2.1 Pengujian Distribusi Multivariat Normal

#### 3.2.1.1 Q-Q Plot Jarak Mahalanobis





Pada Q-Q plot yang diperoleh dari jarak Mahalanobis, titik data (berwarna biru) dibandingkan dengan distribusi Chi-Square teoritis yang ditunjukkan oleh garis merah. Pada bagian awal plot (di bawah nilai 20), titik-titik data mengikuti garis merah dengan baik, yang menunjukkan bahwa sebagian besar data jarak Mahalanobis konsisten dengan distribusi Chi-Square.

Namun, pada bagian akhir plot (di atas nilai 20), terlihat adanya penyimpangan yang lebih besar antara titik data dan garis referensi. Ini menunjukkan bahwa beberapa titik data memiliki nilai yang jauh lebih tinggi dibandingkan dengan distribusi Chi-Square teoritis, yang dapat mengindikasikan adanya outliers atau nilai ekstrim. Secara keseluruhan, data jarak Mahalanobis cenderung mengikuti distribusi Chi-Square pada sebagian besar data, tetapi adanya penyimpangan pada ujung kanan plot menunjukkan bahwa ada beberapa anomali yang perlu diperhatikan. Hal ini menunjukkan bahwa distribusi data sebagian besar sesuai dengan asumsi Chi-Square, namun perlu dilakukan analisis lebih lanjut untuk memeriksa outliers atau data yang tidak biasa.

Secara keseluruhan, Q-Q plot yang diperoleh dari jarak Mahalanobis menunjukkan bahwa sebagian besar data mengikuti distribusi Chi-Square teoritis dengan baik, terutama pada bagian awal plot (di bawah nilai 20). Hal ini mengindikasikan bahwa data jarak Mahalanobis umumnya sesuai dengan distribusi Chi-Square. Namun, pada bagian akhir plot (di atas nilai 20), terdapat penyimpangan yang signifikan antara titik data dan garis referensi, yang menunjukkan adanya nilai ekstrim atau outliers. Penyimpangan ini mengarah pada kemungkinan adanya data yang tidak biasa atau jauh dari distribusi teoritis, yang perlu diperiksa lebih lanjut. Dengan demikian, meskipun data sebagian besar mengikuti distribusi Chi-Square, ada beberapa anomali yang perlu dianalisis lebih mendalam untuk memahami karakteristik data secara keseluruhan.



### 3.2.1.2 Asumsi Normal Multivariat Variabel Respon

```
=== Mardia's Test ===  
Skewness: 0.0332, p-value: 0.0020  
Kurtosis: 8.8987, z-score: 81.6269
```

Hasil Mardia's Test untuk asumsi normalitas multivariat variabel respon menunjukkan dua hal penting: skewness (kemiringan) dan kurtosis. Pertama, nilai skewness sebesar 0.0332 menunjukkan bahwa distribusi data hampir simetris. Nilai skewness yang sangat kecil mendekati nol ini mengindikasikan bahwa data tidak memiliki kemiringan signifikan ke kiri atau ke kanan. P-value untuk skewness adalah 0.0020, yang lebih kecil dari tingkat signifikansi 0.05, namun karena nilai skewness mendekati nol, kita bisa menyimpulkan bahwa tidak ada bukti kuat untuk menolak hipotesis bahwa data memiliki kemiringan normal.

Di sisi lain, nilai kurtosis sebesar 8.8987 menunjukkan bahwa distribusi data memiliki tailedness yang jauh lebih tinggi dibandingkan dengan distribusi normal yang seharusnya memiliki kurtosis sekitar 3. Ini mengindikasikan bahwa data cenderung memiliki lebih banyak nilai ekstrem atau outliers. Nilai z-score untuk kurtosis sebesar 81.6269 sangat tinggi, menunjukkan bahwa distribusi data sangat jauh dari distribusi normal dalam hal kurtosis. P-value yang sangat kecil (jauh di bawah 0.05) mengindikasikan bahwa ada bukti yang kuat untuk menolak hipotesis bahwa data memiliki kurtosis normal.

Secara keseluruhan, meskipun kemiringan data mendekati normal dan dapat diterima, kurtosis data menunjukkan adanya distribusi yang lebih tajam dengan lebih banyak nilai ekstrem atau outliers. Hal ini menunjukkan bahwa data tidak sepenuhnya memenuhi asumsi normalitas multivariat, terutama karena kurtosis yang tinggi, meskipun kemiringannya dapat diterima.

### 3.2.2 Pengecekan VIF Multikolineritas

```
(  
  Variable      VIF  
0      const 35.999081  
1      Income 1.332132  
2       Kids 1.194465  
3 TotalAcceptedCmp 1.179737  
4        Age 1.079431  
5   day_engaged 1.008196,  
  Variable      VIF  
0      const 35.999081  
1      Income 1.332132  
2       Kids 1.194465  
3 TotalAcceptedCmp 1.179737  
4        Age 1.079431  
5   day_engaged 1.008196)
```

Hasil Variance Inflation Factor (VIF) menunjukkan tingkat multikolineritas antar variabel dalam model regresi. Variabel const (Intercept) memiliki nilai VIF sebesar 35.999081, yang menunjukkan inflasi variansi yang sangat tinggi untuk konstanta. Meskipun nilai ini tidak dapat dianggap sebagai indikasi multikolineritas antar variabel prediktor, angka yang tinggi sering kali disebabkan oleh korelasi yang kuat antar variabel dalam model.

Sementara itu, variabel Income memiliki nilai VIF sebesar 1.332132, yang menunjukkan korelasi rendah dengan variabel lainnya, menandakan bahwa multikolineritas pada variabel ini tidak menjadi masalah signifikan. Begitu pula dengan Kids, yang memiliki nilai VIF sebesar 1.194465, yang menunjukkan multikolineritas yang sangat rendah. Variabel TotalAcceptedCmp dengan nilai VIF 1.179737 dan Age dengan nilai VIF 1.079431 juga menunjukkan hasil serupa, yakni tidak ada masalah multikolineritas yang berarti. Terakhir, variabel day\_engaged memiliki nilai VIF sebesar 1.008196, yang menunjukkan hampir tidak ada korelasi dengan variabel lainnya.

Secara keseluruhan, nilai-nilai VIF untuk semua variabel prediktor dalam model ini berada jauh di bawah angka ambang batas 5, yang berarti tidak ada masalah multikolineritas yang signifikan antara variabel-variabel prediktor dalam model. Dengan demikian, model regresi ini dapat dianggap stabil dan tidak terpengaruh oleh korelasi yang tinggi antar variabel-variabel independennya. Hal ini menunjukkan bahwa model regresi ini dapat diandalkan untuk analisis lebih lanjut tanpa adanya pengaruh negatif dari multikolineritas.

### 3.2.3 Seleksi Variabel

```
Remaining variables with VIF <= 10:
Index(['const', 'Income', 'Kids', 'TotalAcceptedCmp', 'Age', 'day_engaged'], dtype='object')
```

Model Summary:

| OLS Regression Results |                  |                     |           |       |          |          |
|------------------------|------------------|---------------------|-----------|-------|----------|----------|
| Dep. Variable:         | Expenses         | R-squared:          | 0.750     |       |          |          |
| Model:                 | OLS              | Adj. R-squared:     | 0.749     |       |          |          |
| Method:                | Least Squares    | F-statistic:        | 1340.     |       |          |          |
| Date:                  | Thu, 12 Jun 2025 | Prob (F-statistic): | 0.00      |       |          |          |
| Time:                  | 14:44:20         | Log-Likelihood:     | -15963.   |       |          |          |
| No. Observations:      | 2240             | AIC:                | 3.194e+04 |       |          |          |
| Df Residuals:          | 2234             | BIC:                | 3.197e+04 |       |          |          |
| Df Model:              | 5                |                     |           |       |          |          |
| Covariance Type:       | nonrobust        |                     |           |       |          |          |
|                        | coef             | std err             | t         | P> t  | [0.025   | 0.975]   |
| Intercept              | -536.3071        | 38.221              | -14.032   | 0.000 | -611.259 | -461.355 |
| Income                 | 0.0195           | 0.000               | 55.569    | 0.000 | 0.019    | 0.020    |
| Kids                   | -178.0053        | 9.263               | -19.218   | 0.000 | -196.170 | -159.841 |
| TotalAcceptedCmp       | 101.3077         | 7.771               | 13.036    | 0.000 | 86.068   | 116.547  |
| Age                    | -0.0493          | 0.552               | -0.089    | 0.929 | -1.133   | 1.034    |
| day_engaged            | 0.4749           | 0.032               | 15.003    | 0.000 | 0.413    | 0.537    |
| Omnibus:               | 262.998          | Durbin-Watson:      | 1.982     |       |          |          |
| Prob(Omnibus):         | 0.000            | Jarque-Bera (JB):   | 2164.646  |       |          |          |
| Skew:                  | -0.221           | Prob(JB):           | 0.00      |       |          |          |
| Kurtosis:              | 7.796            | Cond. No.           | 3.36e+05  |       |          |          |

Berdasarkan hasil OLS Regression untuk variabel dependen Expenses, model ini menunjukkan R-squared sebesar 0.750, yang berarti model ini dapat menjelaskan sekitar 75% variasi dalam variabel Expenses. Nilai Adjusted R-squared sebesar 0.749 juga mendukung kesesuaian model ini, menunjukkan bahwa model tidak terlalu overfit meskipun memiliki banyak variabel independen. Nilai F-statistic sebesar 1340 dengan Prob (F-statistic) yang sangat kecil (0.00) menunjukkan bahwa model secara keseluruhan signifikan dan variabel-variabel dalam model memiliki pengaruh yang signifikan terhadap Expenses.

Melihat nilai koefisien, variabel Income memiliki koefisien 0.0195 dengan p-value yang sangat kecil, menunjukkan pengaruh positif yang signifikan terhadap Expenses. Setiap kenaikan unit pada Income akan meningkatkan Expenses sebesar 0.0195 unit. Kids memiliki koefisien -178.0053, yang menunjukkan hubungan negatif yang signifikan antara jumlah anak dan Expenses. Setiap peningkatan jumlah anak akan menurunkan Expenses sebesar 178.0053 unit. Variabel TotalAcceptedCmp memiliki koefisien positif sebesar 101.3077, yang berarti semakin banyak jumlah kampanye yang diterima, semakin tinggi Expenses. Age memiliki koefisien -0.0493, namun nilai p-value sebesar 0.929 menunjukkan bahwa variabel ini tidak signifikan dalam mempengaruhi Expenses, dan dapat diabaikan dalam model. Terakhir, variabel day\_engaged menunjukkan hubungan positif yang signifikan dengan koefisien 0.4749, yang berarti semakin lama keterlibatan hariannya, semakin tinggi Expenses.

Model ini juga mengindikasikan adanya multikolineritas dengan nilai Condition Number yang besar ( $3.36e+05$ ), yang bisa menunjukkan adanya masalah dengan korelasi yang tinggi antar variabel prediktor. Namun, karena semua nilai VIF untuk variabel-variabel dalam model ini lebih kecil dari 10, tidak ada variabel yang perlu dibuang dari model. Hal ini menunjukkan bahwa meskipun ada indikasi multikolineritas, masalahnya tidak cukup besar untuk menghapus variabel.

Secara keseluruhan, model ini menunjukkan bahwa sebagian besar variabel prediktor yang dimasukkan berpengaruh signifikan terhadap Expenses, dengan pengecualian Age yang tidak memberikan kontribusi yang signifikan. Karena nilai VIF berada dalam batas yang wajar, model ini dapat digunakan tanpa perlu membuang variabel apapun, meskipun perlu memperhatikan potensi masalah multikolineritas yang terdeteksi oleh Condition Number.

### **3.2.4 Pengujian Signifikan Serentak secara Multivariat**

Test of Overall Regression:

<F test: F=1340.0188491101187, p=0.0, df\_denom=2.23e+03, df\_num=5>

Hasil F-test untuk uji regresi secara keseluruhan menunjukkan nilai F sebesar 1340.0188491101187, dengan p-value yang sangat kecil ( $p = 0.00$ ). Nilai F yang besar ini menunjukkan bahwa model regresi secara keseluruhan signifikan, artinya setidaknya satu dari variabel prediktor yang digunakan dalam model memiliki pengaruh yang signifikan terhadap variabel dependen, yaitu Expenses.

Dengan p-value yang lebih kecil dari level signifikansi yang umum digunakan (0.05), kita dapat menolak hipotesis nol yang menyatakan bahwa tidak ada hubungan antara variabel prediktor dengan variabel dependen. Ini menunjukkan bahwa model regresi ini cukup kuat dalam menjelaskan variasi dalam Expenses.

Secara keseluruhan, uji F ini mendukung bahwa model regresi yang telah dibangun signifikan dan memberikan kontribusi yang berarti terhadap pemodelan variabel dependen. Meskipun nilai F yang sangat tinggi mengindikasikan model yang baik, penting untuk tetap memantau dan menguji keberadaan masalah lain seperti multikolineritas yang terdeteksi sebelumnya. Namun, berdasarkan hasil F-test ini, model regresi ini dapat dianggap valid untuk digunakan dalam analisis lebih lanjut.

### 3.2.5 Uji Multivariat untuk Model Regresi Linier

```

Multivariate Test Results:
      Multivariate linear model
=====

-----
Intercept      Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.9184  2.0000  2233.0000  99.2059  0.0000
Pillai's trace  0.0816  2.0000  2233.0000  99.2059  0.0000
Hotelling-Lawley trace  0.0889  2.0000  2233.0000  99.2059  0.0000
Roy's greatest root  0.0889  2.0000  2233.0000  99.2059  0.0000
-----

-----
Income         Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.4038  2.0000  2233.0000  1648.6459  0.0000
Pillai's trace  0.5962  2.0000  2233.0000  1648.6459  0.0000
Hotelling-Lawley trace  1.4766  2.0000  2233.0000  1648.6459  0.0000
Roy's greatest root  1.4766  2.0000  2233.0000  1648.6459  0.0000
-----

-----
Kids           Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.8280  2.0000  2233.0000  231.9416  0.0000
Pillai's trace  0.1720  2.0000  2233.0000  231.9416  0.0000
Hotelling-Lawley trace  0.2077  2.0000  2233.0000  231.9416  0.0000
Roy's greatest root  0.2077  2.0000  2233.0000  231.9416  0.0000
-----

```

| TotalAcceptedCmp       | Value  | Num DF | Den DF    | F Value  | Pr > F |
|------------------------|--------|--------|-----------|----------|--------|
| Wilks' lambda          | 0.9115 | 2.0000 | 2233.0000 | 108.3680 | 0.0000 |
| Pillai's trace         | 0.0885 | 2.0000 | 2233.0000 | 108.3680 | 0.0000 |
| Hotelling-Lawley trace | 0.0971 | 2.0000 | 2233.0000 | 108.3680 | 0.0000 |
| Roy's greatest root    | 0.0971 | 2.0000 | 2233.0000 | 108.3680 | 0.0000 |

| Age                    | Value  | Num DF | Den DF    | F Value | Pr > F |
|------------------------|--------|--------|-----------|---------|--------|
| Wilks' lambda          | 0.9962 | 2.0000 | 2233.0000 | 4.2567  | 0.0143 |
| Pillai's trace         | 0.0038 | 2.0000 | 2233.0000 | 4.2567  | 0.0143 |
| Hotelling-Lawley trace | 0.0038 | 2.0000 | 2233.0000 | 4.2567  | 0.0143 |
| Roy's greatest root    | 0.0038 | 2.0000 | 2233.0000 | 4.2567  | 0.0143 |

| day_engaged            | Value  | Num DF | Den DF    | F Value  | Pr > F |
|------------------------|--------|--------|-----------|----------|--------|
| Wilks' lambda          | 0.8791 | 2.0000 | 2233.0000 | 153.5849 | 0.0000 |
| Pillai's trace         | 0.1209 | 2.0000 | 2233.0000 | 153.5849 | 0.0000 |
| Hotelling-Lawley trace | 0.1376 | 2.0000 | 2233.0000 | 153.5849 | 0.0000 |
| Roy's greatest root    | 0.1376 | 2.0000 | 2233.0000 | 153.5849 | 0.0000 |

Hasil Multivariate Test menunjukkan uji multivariat untuk model regresi linier yang mencakup beberapa variabel prediktor, dengan hasil uji menggunakan beberapa statistik, seperti Wilks' Lambda, Pillai's Trace, Hotelling-Lawley Trace, dan Roy's Greatest Root. Untuk model keseluruhan (yang mencakup semua variabel), semua statistik menunjukkan nilai yang sangat signifikan dengan p-value sebesar 0.0000, yang menunjukkan bahwa model regresi secara keseluruhan signifikan dan variabel-variabel yang digunakan memberikan kontribusi penting terhadap variabel dependen.

Untuk masing-masing variabel prediktor, hasil uji multivariat menunjukkan bahwa variabel-variabel tersebut secara signifikan mempengaruhi variabel dependen (Expenses). Misalnya, untuk Income, semua statistik menunjukkan nilai yang sangat tinggi dan p-value 0.0000, yang mengindikasikan pengaruh yang sangat signifikan dari Income terhadap Expenses. Kids juga menunjukkan hasil yang signifikan dengan p-value 0.0000, artinya jumlah anak memiliki pengaruh yang kuat terhadap pengeluaran. TotalAcceptedCmp, dengan p-value 0.0000, menunjukkan hubungan yang signifikan antara jumlah kampanye yang diterima dan Expenses.

Variabel Age menunjukkan pengaruh yang lebih lemah dibandingkan dengan variabel lainnya, dengan F Value sebesar 4.2567 dan p-value sebesar 0.0143, yang meskipun signifikan, pengaruhnya lebih kecil dibandingkan variabel lainnya. Sedangkan variabel day\_engaged menunjukkan pengaruh yang sangat signifikan dengan p-value 0.0000, yang berarti semakin lama keterlibatan seseorang dalam suatu aktivitas, semakin tinggi pengeluarannya.

Secara keseluruhan, hasil uji multivariat menunjukkan bahwa semua variabel prediktor dalam model ini (Income, Kids, TotalAcceptedCmp, Age, dan day\_engaged) memiliki pengaruh yang signifikan terhadap Expenses, kecuali variabel Age, yang memiliki pengaruh lebih kecil namun tetap signifikan. Semua statistik uji memberikan bukti kuat bahwa model ini memberikan kontribusi yang signifikan dalam menjelaskan variasi dalam pengeluaran (Expenses). Model regresi ini dapat diandalkan untuk analisis lebih lanjut karena variabel-variabel yang digunakan terbukti memiliki hubungan yang signifikan dengan variabel dependen.

### 3.2.6 Ukuran Kebaikan Model Multivariat dalam Analisis Hubungan antara Variabel Respon dan Prediktor

```

Multivariate Test Results:
      Multivariate linear model
=====

-----
Intercept      Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.9184  2.0000  2233.0000  99.2059  0.0000
Pillai's trace  0.0816  2.0000  2233.0000  99.2059  0.0000
Hotelling-Lawley trace  0.0889  2.0000  2233.0000  99.2059  0.0000
Roy's greatest root  0.0889  2.0000  2233.0000  99.2059  0.0000
-----

-----
Income          Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.4038  2.0000  2233.0000  1648.6459  0.0000
Pillai's trace  0.5962  2.0000  2233.0000  1648.6459  0.0000
Hotelling-Lawley trace  1.4766  2.0000  2233.0000  1648.6459  0.0000
Roy's greatest root  1.4766  2.0000  2233.0000  1648.6459  0.0000
-----

-----
Kids            Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.8280  2.0000  2233.0000  231.9416  0.0000
Pillai's trace  0.1720  2.0000  2233.0000  231.9416  0.0000
Hotelling-Lawley trace  0.2077  2.0000  2233.0000  231.9416  0.0000
Roy's greatest root  0.2077  2.0000  2233.0000  231.9416  0.0000
-----

-----
TotalAcceptedCmp Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda  0.9115  2.0000  2233.0000  108.3680  0.0000
Pillai's trace  0.0885  2.0000  2233.0000  108.3680  0.0000
Hotelling-Lawley trace  0.0971  2.0000  2233.0000  108.3680  0.0000
Roy's greatest root  0.0971  2.0000  2233.0000  108.3680  0.0000
-----

```

```

-----
              Age              Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda 0.9962 2.0000 2233.0000 4.2567 0.0143
Pillai's trace 0.0038 2.0000 2233.0000 4.2567 0.0143
Hotelling-Lawley trace 0.0038 2.0000 2233.0000 4.2567 0.0143
Roy's greatest root 0.0038 2.0000 2233.0000 4.2567 0.0143
-----

              day_engaged          Value  Num DF   Den DF   F Value  Pr > F
-----
Wilks' lambda 0.8791 2.0000 2233.0000 153.5849 0.0000
Pillai's trace 0.1209 2.0000 2233.0000 153.5849 0.0000
Hotelling-Lawley trace 0.1376 2.0000 2233.0000 153.5849 0.0000
Roy's greatest root 0.1376 2.0000 2233.0000 153.5849 0.0000
=====

Wilk's Lambda ( $\Lambda$ ) para model keseluruhan: 0.9184
Eta Square Lambda ( $\eta^2$ ) para model keseluruhan: 0.0816

```

Hasil Multivariate Test untuk model regresi linier menunjukkan bahwa nilai Wilks' Lambda untuk model keseluruhan adalah 0.9184, dengan p-value sebesar 0.0000, yang menunjukkan bahwa model regresi secara keseluruhan sangat signifikan. Nilai Wilks' Lambda yang mendekati 1 menandakan bahwa variabilitas data yang dapat dijelaskan oleh model adalah cukup besar, sementara p-value yang sangat kecil menunjukkan bahwa model ini memberikan kontribusi yang sangat signifikan terhadap variabel dependen.

Untuk masing-masing variabel prediktor, Income, Kids, TotalAcceptedCmp, dan day\_engaged menunjukkan hasil yang sangat signifikan dengan p-value yang sangat kecil (0.0000). Hal ini mengindikasikan bahwa semua variabel tersebut memiliki pengaruh yang kuat dan signifikan terhadap variabel dependen. Variabel Age, meskipun memiliki p-value yang sedikit lebih tinggi (0.0143), tetap menunjukkan bahwa pengaruhnya terhadap Expenses signifikan, meskipun dengan pengaruh yang lebih kecil dibandingkan variabel lainnya.

Nilai Eta Square Lambda ( $\eta^2$ ) untuk model keseluruhan adalah 0.0816, yang menunjukkan bahwa sekitar 8.16% dari variasi total dalam data dapat dijelaskan oleh model ini. Meskipun tidak sangat besar, nilai ini menunjukkan bahwa model ini dapat menjelaskan sebagian variasi dalam Expenses dengan cukup baik.

Secara keseluruhan, hasil uji multivariat menunjukkan bahwa model regresi linier ini sangat signifikan, dengan variabel-variabel prediktor seperti Income, Kids, TotalAcceptedCmp, dan day\_engaged memberikan kontribusi yang signifikan terhadap Expenses. Meskipun Age memiliki pengaruh yang lebih kecil, variabel ini tetap signifikan. Model ini mampu menjelaskan sekitar 8.16% dari variasi dalam data, yang menunjukkan bahwa meskipun pengaruhnya tidak besar, model ini memberikan gambaran yang cukup baik tentang faktor-faktor yang mempengaruhi Expenses.

### 3.2.7 Kesimpulan Hasil Analisis Regresi Multivariat

Berdasarkan hasil analisis regresi multivariat yang telah dijelaskan, maka diperoleh kesimpulan sebagai berikut:

1. Statistika Deskriptif: Ditemukan bahwa terdapat hubungan positif antara Income, Kids, TotalAcceptedCmp, dan day\_engaged dengan Expenses, serta hubungan signifikan antara Income dan NumTotalPurchases. Namun, terdapat masalah multikolineritas pada beberapa variabel, yang dapat memengaruhi hasil analisis. Selain itu, model regresi menunjukkan beberapa asumsi yang tidak terpenuhi, seperti normalitas residual yang tidak sempurna, yang dapat berpengaruh pada kestabilan model.
2. Model regresi yang dihasilkan untuk Expenses dan NumTotalPurchases menunjukkan dua variabel respon, yaitu Expenses dan NumTotalPurchases, dengan beberapa variabel prediktor yang berkontribusi dalam model.

Persamaan regresi untuk Expenses adalah sebagai berikut:

$$Y_1 = -536.3071 + 0.0195 \cdot X_2 - 178.0053 \cdot X_3 + 101.3077 \cdot X_4 - 0.0493 \cdot X_5 + 0.4749 \cdot X_6$$

Sedangkan untuk NumTotalPurchases, persamaannya adalah:

$$Y_2 = -3.8148 + 0.0002 \cdot X_2 - 0.1083 \cdot X_3 + 0.0321 \cdot X_4 + 0.0248 \cdot X_5 + 0.0085 \cdot X_6$$

3. Nilai R-squared untuk Expenses adalah 0.750, yang menunjukkan bahwa model dapat menjelaskan sekitar 75% variasi dalam Expenses. Sementara itu, model untuk NumTotalPurchases menunjukkan R-squared sebesar 0.512, yang berarti model ini hanya menjelaskan sekitar 51% variasi dalam NumTotalPurchases. Dengan kata lain, model untuk Expenses lebih baik dalam menjelaskan variasi data daripada model untuk NumTotalPurchases.
4. Nilai Condition Number yang tinggi ( $3.36 \times 10^5$ ) menunjukkan adanya multikolineritas yang kuat atau masalah numerik lainnya dalam model. Hal ini perlu diperhatikan karena dapat mempengaruhi kestabilan dan interpretasi koefisien dalam model.


### 3.3 Analisis Korespondensi Berganda

Analisis Korespondensi Berganda (MCA) merupakan metode statistik eksploratif yang dikembangkan untuk menangani dan memvisualisasikan struktur data multivariat yang bersifat kategorik. Teknik ini secara langsung merupakan ekstensi dari *Correspondence Analysis* (CA) yang ditujukan untuk dua variabel kategorik, dengan MCA diperluas untuk lebih dari dua variabel (Greenacre, 2010).



Pada kasus dataset ini, kita bisa menyelidiki asosiasi dari variabel-variabel kategorik di dalamnya. Tiga skenario eksplorasi akan dilakukan untuk mengamati hubungan antar variabel, antara lain Gaya Hidup dan Preferensi Konsumsi, Status Sosial dan Perilaku Online, Respons Kampanye dan Aktivitas Online.


Untuk skenario pertama, yaitu Gaya Hidup dan Preferensi Konsumsi. Pada skenario ini, pelanggan dikelompokkan berdasarkan pola konsumsi produk harian dan minuman untuk memahami gaya hidup (misalnya : apakah pelanggan cenderung “foodie”. “Healthy”, atau “budget-conscious”). Variabel-variabel pada dataset yang digunakan dalam skenario ini antara lain “MntWines”, “MntFruits”, “MntSweetProducts”, “MntGoldProds”, dan “NumDealsPurchases”. Semua variabel numerik dikategorikan menggunakan kuantil agar bisa dianalisis dengan MCA. Perhatikan output biplot berikut untuk skenario ini.



Perhatikan kelompok titik-titik “MntWines\_cat\_tinggi”, “MntSweetProducts\_cat\_tinggi”, dan “MntGoldProds\_cat\_tinggi” berada di kuadran kanan-bawah. Kelompok ini menggambarkan pelanggan dengan preferensi terhadap produk mewah dan gaya hidup yang “indulgent” (menikmati wine, makanan manis, dan produk emas). Kita bisa menyebutnya sebagai segmen high spender atau lifestyle-oriented. Lalu, perhatikan kelompok titik-titik “MntWines\_cat\_rendah”, “MntSweetProducts\_cat\_rendah”, “MntGoldProds\_cat\_rendah” terletak di kuadran kiri-bawah. Kelompok ini cenderung mengeluarkan sedikit untuk produk konsumsi sekunder/luxury. Kemungkinan mereka adalah segmen praktis atau budget-conscious, yang membeli sesuai kebutuhan dasar. Kemudian, “NumDealsPurchases\_cat\_tinggi” ada di tengah atas dan “NumDealsPurchase\_cat\_rendah” ada di kanan bawah. Hal ini menginterpretasikan bahwa mereka yang sering membeli karena promosi (cat\_tinggi) cenderung tidak terlalu ekstrem dalam pola

konsumsinya. Sebaliknya, mereka yang jarang membeli karena promosi (cat\_rendah) cenderung konsisten dengan konsumsi tinggi. Bisa jadi mereka tidak *price sensitive*, di mana mereka tetap belanja meskipun tidak ada promo.

Untuk skenario kedua, yaitu Loyalitas dan Ketidakpuasan. Pada skenario ini, akan dieksplorasi asosiasi antara kategori-kategori dari variabel yang mencerminkan loyalitas pelanggan dan tingkat ketidakpuasan atau masalah layanan. Variabel kualitatif yang dimasukkan, antara lain “Response”, “Complain”, “WebVisitLevel”. “AgeGroup”, “Recency”. Sebelum dilakukan analisis MCA, variabel “WebVisitsMonth” dan “Age” dikonversi menjadi kategori menggunakan metode binning. Perhatikan output biplot untuk skenario ini.



Dari visualisasi biplot di atas, terlihat bahwa di sebelah kanan terdapat titik-titik kelompok “Response\_1”, “Recency\_baru” dan “NumWebVisitsMonth\_jarang” lalu di sebelah kiri terdapat titik-titik kelompok “Recency\_lama” dan “NumWebVisitsMonth\_serang”. Artinya, dimensi ini bisa mencerminkan keterlibatan aktual vs sekadar browsing. Kemudian, pada dimensi 2 didominasi oleh “Complain\_1” di bagian atas. “Complain\_1” in sangat jauh dari titik-titik lain, menunjukkan bahwa mengeluh adalah atribut yang sangat khas, dan tidak terlalu berkorelasi dengan variabel lain. Kemudian, “Complain\_0” berada dekat dengan pusat, menunjukkan bahwa mayoritas pelanggan tidak mengeluh dan mereka tersebar di berbagai tipe lainnya. Dimensi ini bisa mencerminkan kepuasan atau ketidakpuasan pelanggan.

Kita bisa menarik beberapa hal dari pemaparan di atas. Pelanggan yang baru membeli dan merespons kampanye umumnya tidak sering mengunjungi situs dan tidak mengeluh. Mereka mungkin membeli karena kampanye spesifik, bukan karena sering browsing. Kemudian, ada segmen “pengunjung pasif” yang sering ke situs, tetapi tidak merespons dan tidak membeli.

Untuk skenario ketiga, yaitu Status Sosial dan Perilaku Online. Pada skenario ini, akan diidentifikasi pola asosiasi antara status sosial konsumen dan perilaku mereka dalam berinteraksi dengan platform online perusahaan. Variabel-variabel kualitatif dalam skenario ini mencakup “Marital\_Status”, “Education”, “AgeGroup”, “WebVisitLevel”, dan “Complain”. Perhatikan output biplot berikut untuk skenario ini.



Dari output di atas, terdapat beberapa pengamatan penting yang bisa diambil. Kategori seperti “Marital\_Status\_Married”, “Together”, dan “Divorced”, serta kelompok usia 30-50 dan >50, muncul berdekatan di sekitar pusat grafik. Ini menunjukkan bahwa kategori tersebut tidak memiliki asosiasi yang kuat secara spesifik terhadap perilaku digital tertentu, seperti keluhan atau intensitas kunjungan. Kemudian, “AgeGroup\_<30” berada jauh dari pusat dan relatif dengan dengan “Complain\_1” dan “Response\_1” menyiratkan bahwa konsumen muda lebih aktif dalam menyampaikan keluhan dan lebih cenderung merespons kampanye. Kategori ini juga dekat dengan “WebVisitLevel\_tinggi”, menunjukkan aktivitas digital yang intens. Lalu, “Marital\_Status\_YOLO” dan “Marital\_Status\_Absurd” muncul sangat jauh dari kluster utama. Hal ini disebabkan ada kesalahan dalam penginputan data. Kemudian, “Education\_Basic” cukup terpisah dan berasosiasi dengan “Complain\_1”, yang mengindikasikan kecenderungan lebih tinggi untuk menyampaikan keluhan dari kelompok dengan pendidikan rendah. Selain itu, “Education\_PhD” berdekatan dengan “WebVisitLevel\_rendah”, yang bisa mengarah pada interpretasi bahwa konsumen dengan tingkat pendidikan tinggi lebih jarang mengunjungi website perusahaan.

Sehingga, kita bisa menarik implikasi analitis dari pemaparan di atas. Konsumen muda dengan aktivitas digital tinggi menjadi target yang baik untuk kampanye online, sekaligus

kelompok yang perlu pendekatan pelayanan pelanggan yang sensitif terhadap keluhan. Kategori usia dan status sosial yang lebih stabil (menikah, >50 tahun) menunjukkan perilaku online yang netral, sehingga pendekatan kampanye bisa lebih konservatif. Terakhir, kategori outlier perlu evaluasi ulang agar tidak mempengaruhi hasil analisis lanjutan.

## **Kesimpulan**

Secara keseluruhan, ketiga skenario analisis multivariat ini menunjukkan bahwa metode eksploratori seperti Multiple Correspondence Analysis efektif dalam mengungkap hubungan laten antar kategori variabel kualitatif dalam data konsumen. Skenario pertama menunjukkan keterkaitan kuat antara tingkat pengeluaran dan loyalitas, yang mencerminkan nilai ekonomi pelanggan. Skenario kedua mengungkap bahwa konsumen yang tidak puas cenderung merespons kampanye pemasaran, memberikan sinyal penting bagi strategi retensi. Sementara itu, skenario ketiga menunjukkan bahwa status sosial, khususnya usia dan pendidikan, berkaitan dengan intensitas aktivitas digital dan kecenderungan menyampaikan keluhan. Ketiga analisis ini memberikan wawasan yang dapat dimanfaatkan untuk segmentasi, penargetan, dan pengelolaan interaksi pelanggan secara lebih tepat sasaran.

## DAFTAR PUSTAKA

Chung, CJF., Fabbri, AG., Van Westen, CJ. (1995). *Multivariate regression analysis for landslide hazard zonation*. Springer.

Greenacre, M. (2010). *Correspondence analysis*. *Wiley Interdisciplinary Reviews: Computational Statistics*.

## LAMPIRAN

Link Google Drive : [📁 Final Project AnMul](#)